Christos：一个具备来源感知输入解析与出处追踪的本地反应预测系统

文章类型：软件研究论文
作者：Dong Xinchang
单位：北京中医药大学中药学院，北京，中国
通讯作者：[待填写]

摘要

背景：反应模板能给出候选产物，但生成结果所依据的原始记录、触发模板和条件证据经常没有随产物一起显示。放到中医药（TCM）数据里，这个问题会放大：同一个中文药名可能指向药典条目、炮制品、地区别名或植物物种，方名也可能对应组成不同的历史版本。

方法：Christos 是一个本地运行的反应预测系统，支持正向枚举、逆合成和逐条结果追踪。程序接受五类输入，数据库以只读方式打开，每一条候选产物都带着模板、源成分、反应轮次、条件标记和不确定性标记。我们分别考察了 USPTO-50k 上的正向召回、以 ORD 目标衡量的逆向覆盖、多步路线恢复，以及中医药输入解析与出处字段。

结果：50,016 条 USPTO-50k 反应中，选定配置取得 91.69% 的单步候选集合召回（45,862 条命中；Wilson 95% CI 91.45% 至 91.93%），基线为 58.73%。官方 5,001 条测试切分上，候选集合召回 91.71%，top-1 43.28%；在 USPTO-MIT（479,035 条）中按确定性规则抽取 39,176 条，候选集合召回 71.18%，top-1 32.81%。逆向搜索在 5,002 个目标、79,184 条模板的组合下取得 94.74% 的 any-hit 覆盖率，在全部 50,016 个目标和 3,065 条泄漏受控模板下为 79.81%；300 个目标中，深度不超过 2 和 3 时路线发现率分别为 47.67% 和 72.33%。本地数据层包含化合物 31,646 个、药材-成分关联 110,686 条、COCONUT 化合物 269,105 个，方剂记录 6,743 条、药典方剂条目 1,526 条；正向运行时模板库含 9,770 条精选模板和 41,619 条从 ORD 反应记录中挖掘的模板。与八篇论文的回溯性计算核对中，五条选定水解案例都复现了文献产物的连接层结构，都用预期水解规则和断裂键类型命中，并把引擎路径与文献路线逐条对照；以 PubChem 立体结构为参照，三例复现了精确立体异构体，乌头碱两例各有一个手性中心在一侧未指派，只能确认连接层一致。

结论：Christos 把输入记录、反应路径和候选产物放在同一条可检查的记录链上，“证据不足”也会被保留下来。基准数字反映反应引擎在指定测试设置下的表现，不能直接外推到化学可行性、生物活性或临床疗效。

关键词：反应预测；逆合成；天然产物；中医药；出处追踪；可复现性；反应模板

引言

实验数据或量化计算数据不足时，模板法常被用来先列出可能产物。RDKit 负责分子对象和基础化学操作（RDKit, 2024）；RDChiral 处理带立体化学的模板抽取和应用（Coley et al., 2019）；AiZynthFinder、Retro* 则把模板库接到搜索和排序过程上（Genheden et al., 2020; Chen et al., 2020）。USPTO-50k、PaRoutes 和 ORD 分别提供了常用测试集、路线基准和带实验背景的反应记录（Schneider et al., 2016; Genheden & Bjerrum, 2022; Kearnes et al., 2021）。

同一个模型换一套目标集或模板库，报告出来的召回率就可能不同。Maziarz et al.（2025）在统一框架中复评逆合成算法时观察到了这种差异；Torren-Peraire et al.（2024）则显示，单步模型的选择会传导向多步规划结果。读到召回率时，目标集、模板库、候选上限和过滤规则都需要一并核对。

天然产物场景还要求程序说明结果从何而来。底物来自哪条输入记录、哪个模板被调用、化合物由哪个本地来源提供、条件证据是实测记录还是一般规则，上述信息不能只靠最终产物回答。同一个界面既接收分子，也接收药材、物种和方剂；标识符层级一旦混用，就容易出现表面精确、实际错配的结果。

中医药数据里，这样的错配很常见。中文药名可能指药典条目、炮制品、地区别名或植物物种，方名也可能带着不同的历史组成。化合物既可能来自药材专库，也可能来自 COCONUT 一类物种级天然产物库（Sorokina et al., 2021）。

Christos 的实现从输入解析开始。每类输入有自己的查找路径；无法解析的词元原样返回；出现多个候选时，程序不会替用户挑一个“看起来最像”的。SQLite 只以只读方式连接。产物记录保留源成分、规则、轮次、条件标记和不确定性标记。公开演示使用固定目录，任意目标逆合成、自由试剂、可购砌块和供应商链接都不开放。

本文用公开反应基准检查引擎性能，再单独检查中医药输入解析和出处字段。两部分的评价对象不同。前者看候选能否覆盖已知产物，后者看系统是否选对来源、是否如实保留已知与未知。所有候选仍是待实验检验的化学假设。

材料与方法

系统组成

代码按职责分为六块，表 1 给出每块的入口与主要实现：

组件	功能	主要实现
输入解析	中药名、拉丁物种、COCONUT 物种、方剂或 SMILES	`sources/herb.py`、`sources/coconut.py`、`sources/formula.py`
反应枚举	正向模板应用与级联扩展	`core/smartreact_engine.py`、SmartReact（MolecularAI，2.0.1）
逆合成	模板反转与有界路线搜索	`tools/retro_search.py`
条件层	反应类别档案与逐模板条件窗口	`conditions/`、`data/mined_top_template_conditions*.json`
出处与报告	台账、索引、HTML 报告和来源标签	`core/query_base.py`、`tools/make_report.py`
界面	命令行与本地浏览器界面	`integration/tcmai_bridge/`

来源适配器与反应引擎彼此独立。药材、物种、方剂或用户分子进入同一套反应代码后，输入侧的出处仍随产物保留。运行环境为 Python 3.12，使用 RDKit、rdChiral、SmartReact 和 SQLite；DuckDB 只出现在离线基准脚本中。

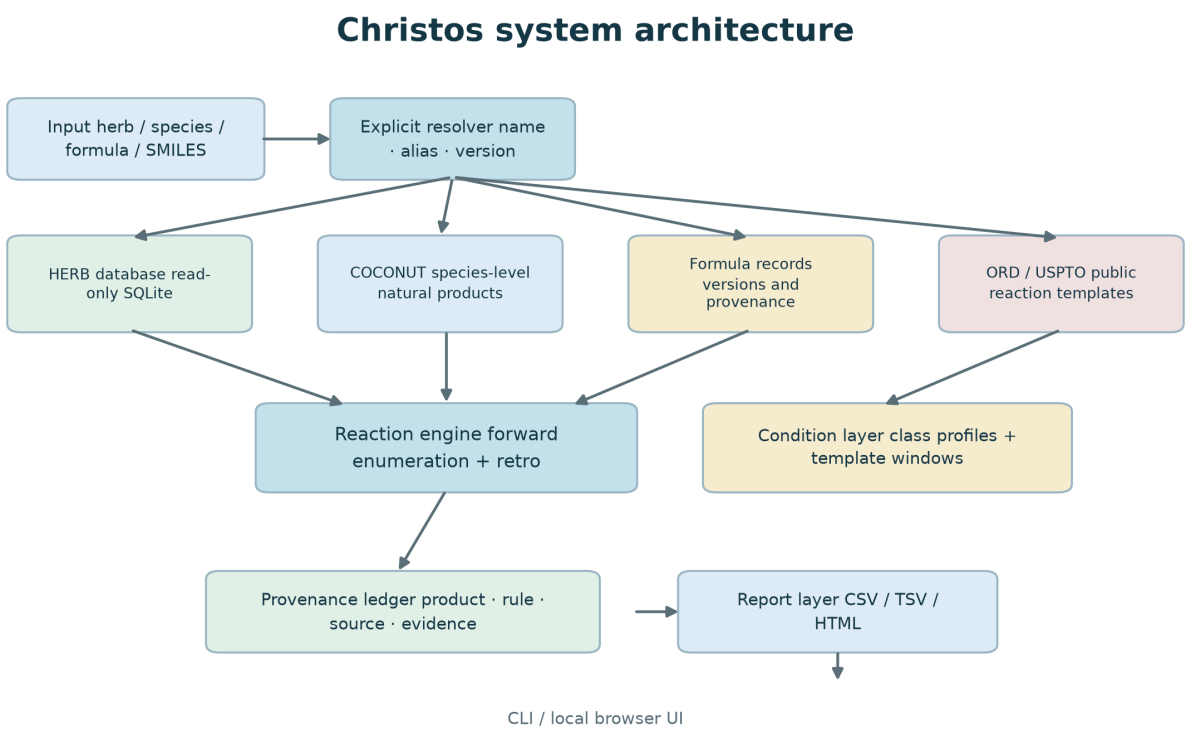


图 1. Christos 的输入与输出路径。化学模块开始运行前先解析输入；来源适配器不写入数据库；候选产物连同出处字段写入台账，再生成 CSV/TSV 和单文件 HTML。

数据源与只读策略

本地版本加载以下资源；下表列出用途、规模与处理方式：

资源	用途	规模	处理方式
药材数据库（`tcm.db`）	药名、成分、别名与证据	31,646 条成分记录（25,486 个不同 SMILES）	只读 SQLite
COCONUT 快照	物种级天然产物	269,105 个有效分子	只读 SQLite
方剂记录	多味方剂与版本	6,743 条	只读 JSON
药典 overlay	2025 年版方剂条目与来源 URL	1,526 条	内部使用，不再分发
USPTO-50k	泄漏受控基准	50,016 条反应	公开基准
正向模板	精选模板包 + 从 ORD 挖掘的模板	9,770 条精选 + 41,619 条挖掘	派生数据，署名
逆合成模板	聚类后的逆向模板	3,228 条（编译后 3,025）	派生数据，署名

上游原始数据库不随本项目重新分发。ORD 派生模板按 CC BY-SA 4.0 处理；USPTO-50k 为 CC0（figshare 5104873）；COCONUT curated dataset 为 CC0，基础设施代码为 MIT；SmartReact 模板包为 Apache-2.0。本地药材和方剂资源还需库主授权，不会进入公开归档。

SQLite 连接统一加 `mode=ro`。如果 WAL 数据库因共享内存文件缺失而打不开只读连接，适配器会改用 `immutable=1` 读快照，边车文件不会新建。这一分支来自一次实际故障：普通 `sqlite3.connect()` 即使只准备读取，也可能生成 `-wal` 和 `-shm`。

公开演示收录 100 味常用药材，每味对应一个拉丁物种，另含 50 个方剂和 150 条预计算示例。方剂控制在 4 至 6 味，并先经过安全过滤再打包。页面没有任意 SMILES 入口，也不接受路线查询。

输入解析

Christos 接收药材名、拉丁物种、COCONUT 物种、方名或一组 SMILES。药材名按以下顺序解析，直到某一层返回结果：

1. 在药材数据库中精确匹配药材名或炮制品名；
2. 炮制品检查：若药典收载的炮制品不在库中，返回“库中无此条目”，不拆回基原，也不转入别名匹配；
3. 在别名词典和药材别名列中查询，返回全部候选，不在候选之间自动选择；
4. 在人工整理的同义词表中查询，得到单一规范名；
5. 匹配中文名子串，最多返回 40 个候选，并按名称长度排序；
6. 匹配拉丁名、英文名或别名字符串；
7. 以不低于 0.85 的相似度做模糊匹配，最多返回一个候选。

拼音路径已经移除，因为查询 `gancao` 时曾匹配到秤杆草（`chenggancao`）。

解析结果同时包含选中的记录和未解开的词元。方剂保留同名版本列表，再按来源层级选出一个版本。若把不同版本强行拼成一张处方，得到的组成不符合任何历史或药典条目。

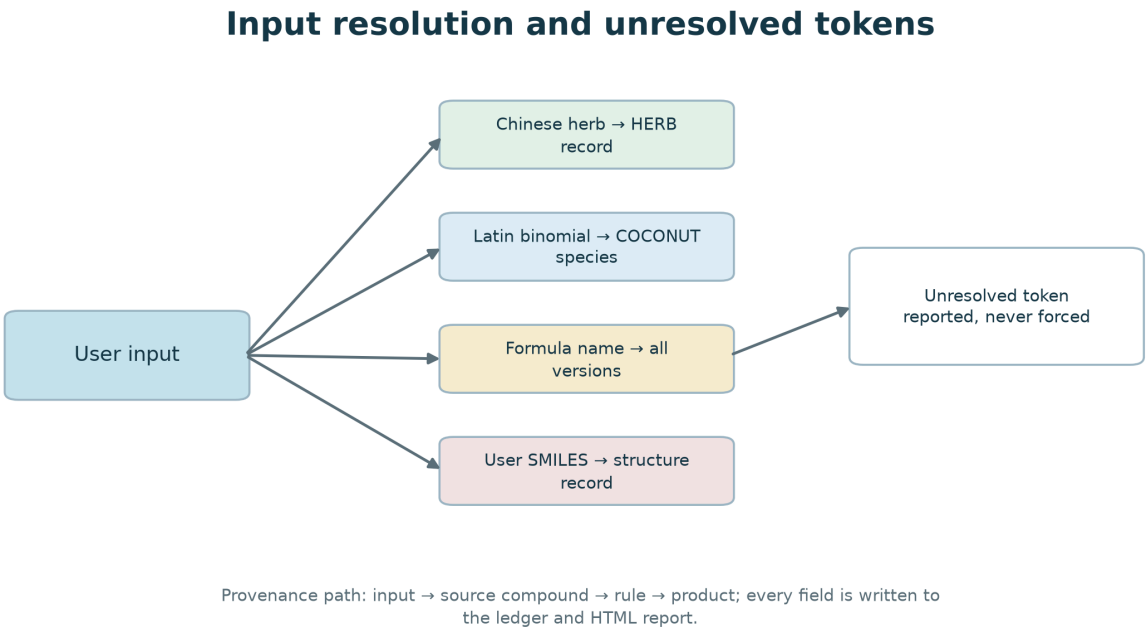


图 2. 药材名、拉丁物种、方名和 SMILES 的解析路径。未匹配词元按原样返回，不强行归入某条记录。

正向反应枚举

正向枚举对底物集合逐个应用模板。模板先按反应名称归组，再按反应物类别过滤。运行参数包括每味药的成分数、反应轮数、底物对上限，以及每个底物对保留多少候选。

选定配置采用支持度过滤的模板池，每个底物对最多保留 32 个产物，并启用底物兼容性预筛。即使模板已经命中，候选上限仍可能截掉正确产物。运行记录因此一并保存底物对覆盖率和截断状态；发生截断时，结果按不完整枚举处理。

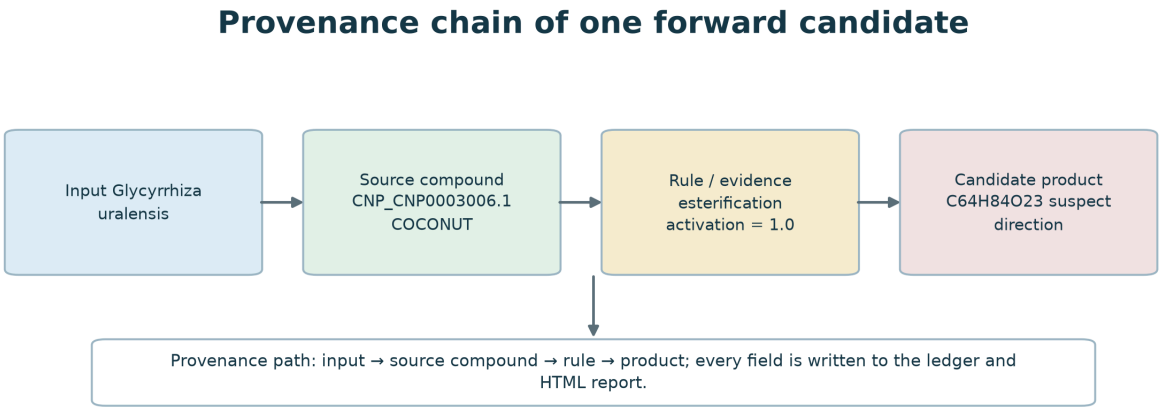


图 3. 一条正向候选及其在出处台账中保留的字段：输入物种、源成分、规则、条件证据标记和候选产物。

逆合成

逆合成把正向模板反向应用，从目标分子逐层给出切断、前体和整条路线的标注。前体与终止集合比对后，标为可用或不可用。查不到只说明本地终止集合里没有它，不能据此判断现实中买不到或做不出。

公开版本不开放任意目标逆合成。研究命令需通过单独环境变量启用这项功能。它只改变公开界面的功能范围，不能当作安全屏障。

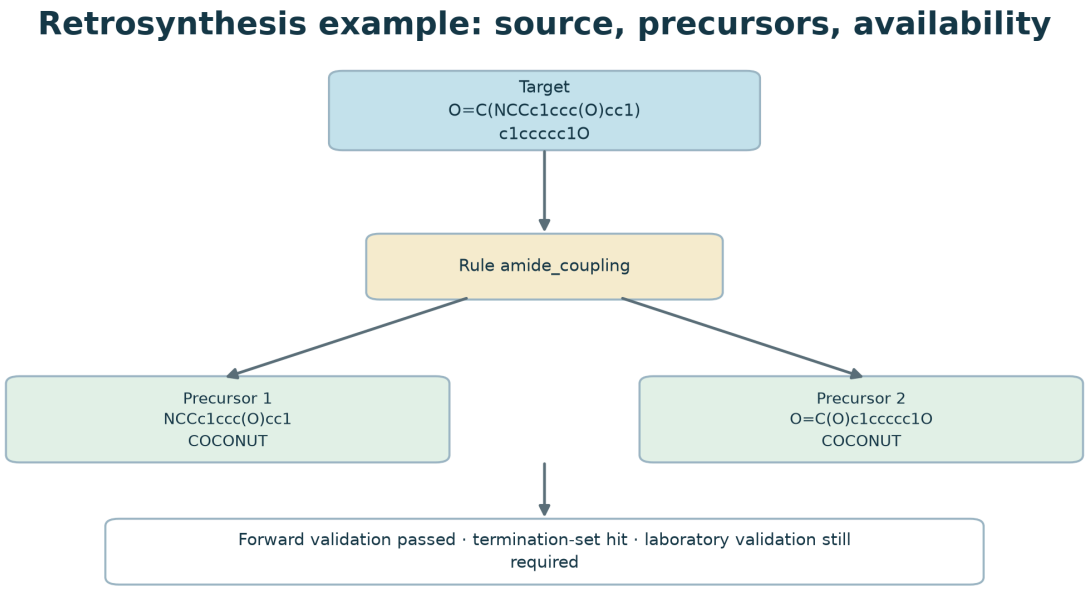


图 4. 一条单步逆合成路线，两个前体命中当前终止集合，正向验证也通过。这是标注，不是实验室操作指令。

条件证据

条件证据来自两类记录：

- 命名反应类别的条件档案，包括溶剂、pH、温度、催化剂和气氛窗口；
- 从 ORD 记录中挖掘的逐模板窗口；只有模板重现了记录中的产物，才收集该记录的条件。

逐模板层从均匀抽取的 ORD 样本开始。模板必须先在记录中重现产物，之后才采用这条记录的条件。500 条受审模板里，493 条至少有一次产物匹配，491 条由此得到至少一个条件类别。条件窗口仅作标注，不计算动力学、收率或选择性。

出处与报告

台账路径逐条保存以下字段：产物结构、源成分、药材或物种来源、反应规则、轮次、条件标记、方向标记和证据文字。报告生成器读取上述字段，输出单文件 HTML，并可按需绘制结构。

方向和条件标记只改变显示内容，不删候选。“无证据”表示当前记录中没有找到匹配条件，不表示反应必然不会发生。

文献一致性验证

我们在运行当前版本前固定了五个案例：甘草酸到甘草次酸、人参皂苷 Rb1 到 Rg3、乌头碱两步酯水解，以及芦丁到槲皮素。文献通过 PubMed 检索；主运行的底物、产物和中间体均来自本地只读成分表。每个案例再用 PubChem 的立体参考结构重跑一次，分别比较连接层和完整立体结构。

每个底物单独使用煎煮条件运行一轮，开启 `strict_redox_gate=True`，每个底物对最多保留 64 个产物。产物命中要求规范化结构与文献产物一致。随后核对命中规则、规则模板中断裂的映射键、底物与产物的分子式差，以及文献中间体是否出现。对本地库中存在的中间体再单独运行一轮，检查它能否继续生成目标产物。这是一次计算实验：系统在煎煮条件下运行，把产物与路径同文献对照。系统在自身条件下复现了文献产物；它不复制文献的物理条件、产率或选择性。

评价设计

正向预测

每条 USPTO-50k 记录只跑一轮，把记录中的反应物作为输入。只要目标产物出现在候选集合中的任意位置，就计为命中；评价不排序。评价覆盖全部 50,016 条反应，随机种子为 20261014，使用 6 个工作进程。

泄漏受控模板库先从全部 ORD 分片挖掘，再按产物去重。标准化并删除原子映射号后，只要产物与任一 USPTO-50k 测试产物相同，对应 ORD 记录就不计入模板；反应物是否相同不影响这一判断。两组逆向模板库也按同样规则处理。来源不同，最终规模不同：5,002 个目标的实验使用 79,184 条模板，全部 50,016 个目标的实验使用 3,065 条。

同一选定配置在过滤库和未过滤库上分别得到 91.69% 和 91.97%，相差 0.28 个百分点。就这组比较而言，模板与测试集重合只能解释一小部分结果。

基线保留引擎默认设置，每个底物对最多 8 个产物，不加额外模板池，也不启用兼容性预筛。选定配置把上限提高到 32，再加入约 20,000 条、支持度至少为 10 的模板，并打开预筛。

基线候选中位数为 8，选定配置的第 90 百分位为 32，两组都已碰到各自上限。基准脚本从环境变量读取参数，结果文件只保存汇总；运行参数只能从引擎默认值和变更记录还原，原运行清单没有留下完整配置。消融未测到兼容性预筛的增益，但选定流程仍保留它。

系统本身不对候选排序，因此评价对象是完整候选集合的召回率；Precision at k 依赖一个并不存在的排序。用户最后看到的是带出处的候选集合，第一行没有特殊地位。

逆向覆盖率

逆向命中要求至少一个切断在去除原子映射号后，得到与记录完全一致的反应物集合。5,002 个目标和 300 个目标均取自 ORD，限制为分子量不超过 500、单组分、无盐形式，并从 parquet 约第 200,000 行开始抽取、去重。一组使用 5,002 个目标和 79,184 条模板；另一组使用全部 50,016 个目标和 3,065 条泄漏受控模板。由于目标集和模板库同时变化，两组覆盖率只能分别报告。

多步测试使用束宽 4，每次扩展最多保留 400 个切断。搜索只要返回路线，就算“找到路线”，这条路线未必通过可用性检查。每一步都通过 `retro_search.step_usability` 才算可用路线；目标只要有一条可用路线，就算可用目标。“找到路线”比“找到可用路线”宽松。

中医药解析与出处

药材、物种、方剂和 SMILES 都从同一接口进入。每轮记录解析来源、版本、未解析词元和输出链接。演示示例由同一引擎生成，打包时固化为预计算结果，公开包中没有生产数据库。

实验配置

实验	目标集	模板库	产物级过滤	可比较对象
正向基线	50,016 条 USPTO-50k	引擎默认	是，按 USPTO-50k	正向选定配置
正向选定	50,016 条 USPTO-50k	约 20,000 条支持度过滤模板	是，按 USPTO-50k	正向基线
逆向子集	5,002 个 ORD 目标	79,184 条	是，并检查目标重合	无
逆向全量	50,016 个 USPTO-50k 目标	3,065 条	是	无
多步	300 个 ORD 目标	选定模板库	未做目标重合检查	无
条件审计	500 条模板	生产库	不适用	无
药材解析	75 个固定输入	不适用	不适用	无

正向两组共用目标集，只有配置不同，可以直接比较。逆向实验同时更换了目标集和模板库，只能并列展示。多步实验沿用选定模板库，没有再做目标级重合检查。

结果

已实现的数据规模

本地版本从药材库索引了 31,646 个化合物和 110,686 条药材-成分关联，另含 269,105 个 COCONUT 化合物、6,743 条方剂记录和 1,526 条药典方剂条目。正向运行时模板库由 9,770 条精选模板和 41,619 条从 ORD 反应记录中挖掘的模板组成；默认配置从挖掘库加载 14,140 条双底物模板和 1,045 条单底物模板。逆向搜索另用一套聚类库，共 3,228 条（编译后 3,025 条）。公开演示另含 100 味药材和 50 个方剂。

药材表保存药材与成分的关联，没有先做全局去重。31,646 条记录去重后得到 25,486 个 SMILES，按记录计的重复率为 19.5%。其中 30,964 条带 InChIKey，共对应 29,013 个不同键。另有 682 条没有 InChIKey，因此不同键数不能直接与不同 SMILES 数对照。某个成分或方剂不在统计中，只说明本次本地快照没有它。

正向预测

泄漏受控的 USPTO-50k 实验覆盖 50,016 条反应。基线单步召回率为 58.73%（Wilson 95% CI 58.30% 至 59.16%），每条反应平均返回 10.4 个候选，中位数 9，第 90 百分位 16；另有 0.05% 的反应没有返回候选。选定配置的召回率为 91.69%（45,862/50,016；Wilson 95% CI 91.45% 至 91.93%），平均候选数为 21.3。三进程完成一次完整运行用了 1,596 秒。

58.73% 是 2026-10-30 冻结的测量值。按同一配置在当前代码上重跑（每个底物对最多 8 个产物、不装额外模板池、关闭预筛），得到 55.53%，候选分布完全一致（均值 10.3、中位 9、第 90 百分位 16、空集 0.05%）。两次运行在类别 4、5、6、7、8、9 上一致到 ±0.2 个百分点；差异集中在类别 1、2、3、10（当前代码 54.8、75.9、56.8、0.0，冻结值 60.5、79.7、59.0、66.5）。这四类都依赖双组分 mined 模板，而双组分模板在产物上限为 8 时会被截断。类别 10 的情况最清楚。NBS 苄位溴化模板仍在库中（支持度 2,313），也仍能编译，但它们全部来自挖掘池。这次复现把池关掉了，于是类别 10 一个产物都不出（平均候选 0.0，0/230），所以那个 0 度量的是空候选列表，不是丢了某条转化。若池开着、上限仍为 8，该类回到 41.3%（95/230）；生产档上限 32 时是 87.4%（201/230）。上限为 8 时剩下的差距，才是候选顺序与上限的交互，不是模板缺失。它也无法用二分查找定位：冻结那次早于第一个提交，可重建的最早快照在上限为 8 时只有 40%（立体关 36.7%），上限放到 32 时为 83–87%。下表逐类数值取冻结那次，与 58.73% 和 91.69% 两个头条数字同源；我们保留冻结值以与其余冻结测量保持一致，同时列出当前代码的值。

两组配置都表现为候选越多、召回越高，因此两个数字需要一起理解。基线上限为 8，中位数接近 8；选定配置上限为 32，第 90 百分位已经超过 32。截断确实发生，表中召回率只覆盖上限以内的结果。

在固定抽取的 500 条分层反应样本上进行的消融如下：

配置	召回率	平均候选数
引擎默认	46.60%	10.3
每对上限 32	58.20%	14.8
加入 20,000 条支持度过滤模板	84.80%	19.6
上限从 32 改为 64	85.00%	19.7
加入底物兼容性预筛	84.80%	19.6

把上限从 32 提到 64 后，召回率提高 0.2 个百分点，平均候选数只增加 0.1。兼容性预筛在这一样本上也没有可测作用。增益主要来自更高的每个底物对上限和更大的模板池；这些数字不能证明新增模板在化学上成立。

500 条样本和全量基准的权重不同。样本给每个反应类别相同配额；全量数据里类别 1 和 2 约占 45%，而且本来召回最高。改成等权后，基线从 58.73% 降到 45.65%，选定配置从 91.69% 降到 85.90%。样本给出的两项估计是 46.60% 和 84.80%，Wilson 区间分别为 42.27% 至 50.98%、81.39% 至 87.68%，都包含对应的等权值。剩余差值仍在 n = 500 的抽样波动范围内。上表的头条结果按全量权重报告，消融表按分层样本报告。

外部测试切分

另外两个切分给正向结果划出边界，模板一条未改。在 RetroComposer 发布的官方 USPTO-50k 测试切分上，5,001 条反应剔除 8 条三反应物记录后为 4,993 条可评数据。同一配置的候选集合召回为 91.71%（4,579 条），top-1 43.28%、top-5 67.75%、top-10 78.85%、MRR 0.5496，平均 21.8 个候选（354 秒，零报错）。同一份代码在 50,016 条全量上的候选集合召回是 92.01%；两个分母相差 0.30 个百分点，头条数字并不依赖这个差。

更难的切分是 USPTO-MIT，体量约为十倍。撰写时无法访问官方切分文件，因此采用确定性抽样：取种子与反应串拼接后 MD5 的前 8 个十六进制位映射到 0 至 9999，保留小于 836 的行，得到 479,035 条中的 39,176 条（8.36%）。该样本上的候选集合召回为 71.18%，top-1 32.81%，top-5 51.89%，top-10 61.68%，MRR 0.4187，平均 20.1 个候选。四个分片的召回差异在 0.6 个百分点以内，top-1 在 0.8 个百分点以内。

我们的模板示例与这两个测试集的严格同反应重合都是零（50,016 条中 0 条，479,035 条中 0 条），所以从 91.71% 降到 71.18% 反映的是反应空间更宽，而不是记住了测试集。

这些数字与已发表的 Transformer 基线不可直接比较。Molecular Transformer、其增广版本、Chemformer 与 Graph2SMILES 在 USPTO-MIT 的 40,000 条官方测试集上报的 top-1 在 90.3% 至 92.8% 之间，且使用官方切分与单一产物；我们的数字是不同切分、不同抽样下约 20 个候选的候选集合召回。列出它们是为了给结果划边界，不是声称更优。

增益来源

各反应类别的召回差异很大。基线在类别 1、2、10 上最高，在类别 4、5、9 上最低；换成选定配置后，弱类别的提升最明显。

类别	n	基线	选定配置
1	15,151	60.5%	93.0%
2	11,896	79.7%	95.8%
3	5,662	59.0%	81.3%
4	909	10.3%	56.7%
5	672	5.7%	83.6%
6	8,237	42.8%	96.5%
7	4,614	60.1%	92.0%
8	811	49.9%	97.3%
9	1,834	22.0%	83.7%
10	230	66.5%	79.1%

类别 5 提高了 78.0 个百分点，类别 9 提高 61.7，类别 6 提高 53.8，类别 8 提高 47.3。类别 2 提高 16.1，类别 10 提高 12.6。这些变化与弱类别覆盖缺口相符，但本次比较没有检查新增模板的化学反应是否正确。

候选重排序

召回率只要求产物出现在候选列表里。在用于衡量排序空间的 2,997 个反应上，记录产物排在首位的占 42.71%，位次中位数是 2（90 分位 12），出现在列表任意位置的占 92.56%。42.71% 与 92.56% 之间的差额因此属于顺序问题，而不是覆盖问题。

我们用 12,000 个反应、257,444 个候选训练了一个重排序器。每个候选带九项发射特征（发射位置、模板支持度对数、条件激活分、反应进程、curated 标记、伴生产物标记、产物与底物的重原子数、保留率）、产物侧九个描述量、底物侧九个描述量、两侧的六个差值，外加 30 个高频规则族的一热编码。标签是该候选是否等于记录产物，产物本身只作为标签使用。训练集与测试集按反应哈希对半切开，同一产物没有跨侧出现。

在留出的一半数据上，重排序器把 top-1 从 42.54% 提高到 78.01%，top-5 从 67.93% 提高到 95.63%，top-10 提高到 98.60%，平均倒数秩从 0.546 提高到 0.868，召回率保持 92.00% 不变。只用发射特征的第一版到 66.93%；从那一版去掉发射位置特征，top-1 仍升到 70.32%，说明增益来自候选本身的性质，而不是对基线顺序的复述。

同一个模型以开关形式接进引擎。在官方 5,001 条切分的全部 4,993 条可评数据上，按命令行工具使用的配置（加载 curated 模板并启用严格氧化还原门），召回率保持 92.19%，top-1 从 44.1% 升到 72.6%，top-5 从 67.0% 升到 89.1%，平均倒数秩从 0.552 升到 0.799，没有报错，耗时从 65 秒增至 318 秒。候选集合没有变化，变的只是顺序。

有两条边界需要说明。模型在同分布的 USPTO-50k 上训练与测试；改按类别不交叉划分（1 至 5 类训练、6 至 10 类测试）后，top-1 从 8.61% 升到 19.32%，这说明存在迁移，但这些类别仍明显低于总体水平。中医药流程没有训练数据，因此该开关在这些流程上不外推；此外，重排序并不回答一对分子是否发生反应。

逆合成与多步规划

排除在模板计数之前完成。每条 ORD 记录先与 USPTO-50k 产物集合比对，匹配的记录不计入模板。模板建好后没有再删除。

5,002 个逆向目标与模板挖掘来源的重合情况也查过。252 个目标（5.04%）在来源中出现过，其 any-hit 命中率为 94.84%（239/252）。其余 4,750 个目标为 94.74%（4,500/4,750）。去掉重合目标以后，覆盖率到小数点后两位都没有变化。

两组逆向实验的数值需要分别理解。5,002 个目标配合 79,184 条模板时，any-hit 覆盖率为 94.74%（4,739/5,002；Wilson 95% CI 94.09% 至 95.33%）。全部 50,016 个目标配合 3,065 条泄漏受控模板时，覆盖率为 79.81%。两组实验同时更换目标集和模板库，现有结果无法区分各自贡献。

300 个多步目标没有做同样的重合检查，路线发现率也未做目标级过滤。

使用选定模板库时，束宽为 4 的搜索在深度不超过 2 时找到 47.67% 的路线（143/300；Wilson 95% CI 42.08% 至 53.31%），深度不超过 3 时为 72.33%（217/300；95% CI 67.01% 至 77.09%）。深度 3 以内，207 个目标至少有一条可用路线，占全部目标的 69.0%，占已找到路线目标的 95.4%。深度 2 以内的可用路线数没有单独保存。

每个前体都带着路线级来源和可用状态。“可用”在此仅指记录的步骤通过了本地检查，并不等于实验中可以做通。

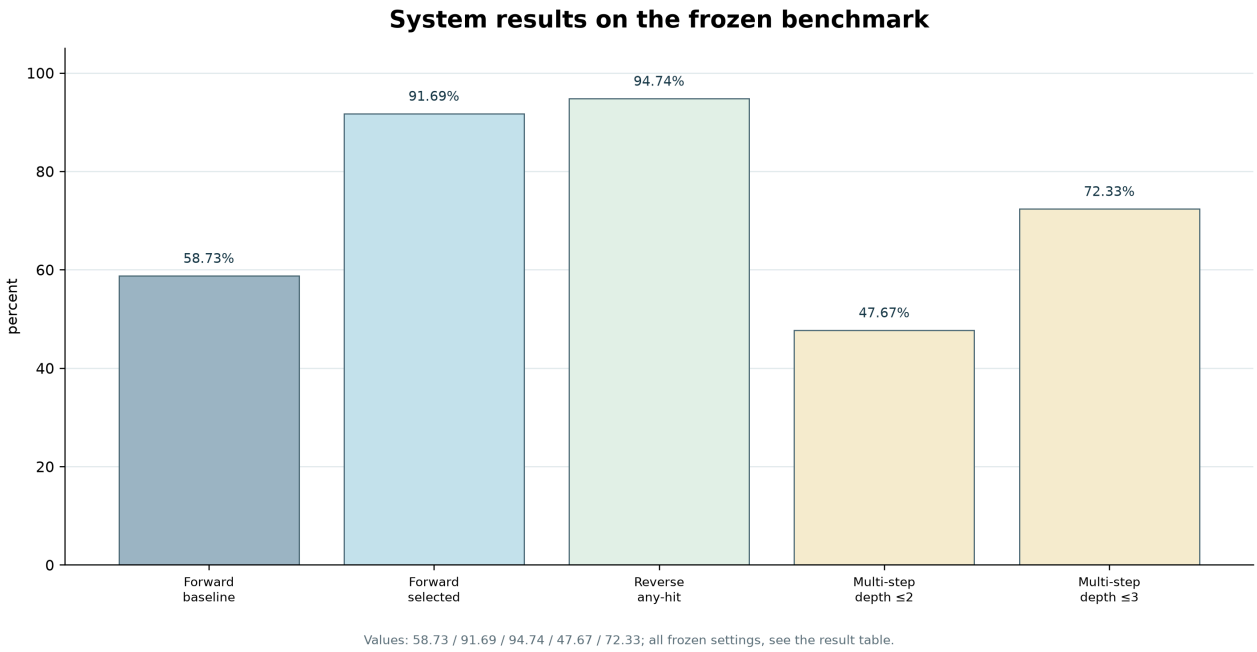


图 5 报告冻结基准上的测量结果。各柱来自不同任务，量纲并不统一。正向单步召回中，基线为 58.73%，选定配置为 91.69%；逆向 any-hit 覆盖率为 94.74%；多步路线找到率在深度 ≤ 2 时为 47.67%，在深度 ≤ 3 时为 72.33%。条件模板核对只写在正文里：500 个审计模板中，493 个至少匹配一个产物，491 个还匹配到条件类别；它表示产物匹配比例，不是召回率。

条件与出处覆盖

正文出现了几类不同计数，需要分别理解。正向运行时库含 9,770 条精选模板与 41,619 条挖掘模板。挖掘库中，默认配置加载 14,140 条双底物模板和 1,045 条单底物模板。约 20,000 条只属于选定基准配置，不是默认库。3,228 条是逆向搜索的聚类库，正向路径从不加载。条件审计则从挖掘库抽了 500 条模板。

每条挖掘模板都记录了来源 ORD 反应，生成模板库的挖掘流程随代码提供。条件审计的 500 条抽样中，493 条至少匹配一个产物；这 493 条中有 491 条还能给出至少一个条件类别，另外两条匹配了产物，却没有得到条件类别。审计结果是独立的数据产物，没有改写运行时库。它基于较早一版挖掘库，尚未在现版重跑。

文献一致性结果

五项文献转化都在计算运行的第一轮得到对应产物，命中路径均使用预设中预期的水解规则。下表候选数来自当前版本，与较早的界面运行不同。

转化	文献	引擎规则	候选数	二维连接层	PubChem 立体
甘草酸到甘草次酸	Fan et al., 2016	`hydrolysis_glycoside_001`	63	命中	精确
人参皂苷 Rb1 到 Rg3	Fu et al., 2017; Ryu et al., 2017; Piao et al., 2020	`hydrolysis_glycoside_001`	102	命中	精确
乌头碱到苯甲酰乌头原碱	Li et al., 2016; Huang et al., 2007	`hydrolysis_ester_001`	24	命中	仅连接层
苯甲酰乌头原碱到乌头原碱	Li et al., 2016; Huang et al., 2007	`hydrolysis_ester_001`	27	命中	仅连接层
芦丁到槲皮素	Kim & Lim, 2017; Yang et al., 2019	`hydrolysis_glycoside_001`	61	命中	精确

引擎路径记录为规则、断裂的映射键、轮次，以及产物减底物的分子式差；下表把它与各论文报告的路线对照。

转化	引擎路径	文献路径	判定
甘草酸到甘草次酸	`hydrolysis_glycoside_001`；C–O 键，第 1 轮；C−12 H−16 O−12	连续与并行水解生成甘草次酸和 3-O-单葡萄糖醛酸苷（Fan et al., 2016）	反应族一致；中间体不在本地库，先后顺序未定
人参皂苷 Rb1 到 Rg3	`hydrolysis_glycoside_001`；C–O 键，第 1 轮；C−12 H−20 O−10	酶转化走 Rb1 → Rd → Rg3；热加工也生成 Rg3（Fu et al., 2017; Ryu et al., 2017; Piao et al., 2020）	第二次运行复现 Rd → Rg3；Rb1 也能直达 Rg3
乌头碱到苯甲酰乌头原碱	`hydrolysis_ester_001`；酯 O–C 键，第 1 轮；C−2 H−2 O−1	脱去 C8 乙酰酯（Li et al., 2016; Huang et al., 2007）	与乙酰基脱落一致；C8 未用原子映射固定
苯甲酰乌头原碱到乌头原碱	`hydrolysis_ester_001`；酯 O–C 键，第 1 轮；C−7 H−4 O−1	脱去 C14 苯甲酸酯（Li et al., 2016; Huang et al., 2007）	与苯甲酰基脱落一致；C14 未用原子映射固定
芦丁到槲皮素	`hydrolysis_glycoside_001`；C–O 键，第 1 轮；C−12 H−20 O−9	切断芦丁糖苷键；异槲皮素也被报道（Kim & Lim, 2017; Yang et al., 2019）	异槲皮素可续到槲皮素；直接切断也一致

系统在 5/5 案例中复现了文献产物的连接层结构，其中 5/5 使用预期反应族和映射键类型。以 PubChem 立体结构为参照时，3/5 复现了精确立体异构体。乌头碱两例各有一个手性中心在一侧未指派，只能算连接层一致。

逐步路径的证据也不整齐。Rb1 → Rd → Rg3 和芦丁 → 异槲皮素 → 槲皮素都能通过两次独立运行复现；乌头碱的两步可作为两个连续案例复现。甘草酸文献同时报告单葡萄糖醛酸中间体和甘草次酸，并指出存在连续和并行水解，但该中间体不在本地库，具体先后顺序无法测试。

这些计算实验统一使用水、100°C、60 分钟、pH 6.5、空气。所引论文使用亚临界水、蒸制、酶转化、酸水解或长时间水解。复现范围限于文献产物和反应族；物理条件、报告产率和条件选择性没有复现。

三个板块与文献记载的对应情况

系统在三种场景下使用：单味药、复方、炮制。连同上一小节的 5 个转化，共核对了 20 个有文献记载的转化。状态里的「结构级」指产物在连接方式上与文献一致，且文献给出立体时立体也一致；「骨架级」指 InChIKey 前 14 位一致，但至少有一个手性中心未确定；「分子式级」指出现了分子式相符的产物，但连接方式与文献不符。

板块	案例	文献记载的产物	规则族	状态
单味药	甘草，煎煮	甘草次酸	`hydrolysis_glycoside_001`	结构级（纳入前体）
单味药	人参，煎煮	Rg3	`hydrolysis_glycoside_001`	结构级（纳入前体）
单味药	附子，煎煮	苯甲酰乌头原碱	`hydrolysis_ester_001`	结构级（纳入前体）
复方	四逆汤	苯甲酰乌头原碱	`hydrolysis_ester_001`	结构级
复方	四逆汤	苯甲酰中乌头原碱	`hydrolysis_ester_001`	结构级
复方	四逆汤	苯甲酰次乌头原碱	`hydrolysis_ester_001`	结构级
复方	四逆汤	乌头原碱	`hydrolysis_ester_001`	结构级
复方	甘草酸，两轮	甘草次酸	`hydrolysis_glycoside_001`	结构级
复方	黄芩汤	黄芩素	`hydrolysis_glycoside_001`	结构级
炮制	蒸制，Rb1	Rg3、Rg5、Rk1	`hydrolysis_glycoside_001`	结构级，三个产物
炮制	炒焦，槟榔碱	去甲基槟榔碱	`demethylation_n_001`	结构级
炮制	蒸制，乌头碱	苯甲酰乌头原碱	`hydrolysis_ester_001`	结构级
炮制	炒黄，苍术苷	苍术苷酸	`decarboxylation_001`	骨架级
炮制	醋炙，Jolkinolide B	开环产物	`hydrolysis_epoxide_001`	分子式级
炮制	蒸制，二苯乙烯苷	苷元	`hydrolysis_glycoside_001`	分子式级

二十个案例中，十七个到结构级，一个到骨架级，两个到分子式级。三个未到结构级的案例原因各不相同，且都没有生成错误的骨架。苍术苷案例里，产物对文献参照有 13 个手性中心，其中 12 个已确定；未确定的那个正是脱羧这一步新生成的，模板无法说明氢从哪一面加。Jolkinolide B 与二苯乙烯苷这两例，PubChem 里没有文献所述产物的参照结构，只能比对分子式。两篇文献的共同点是只描述反

应、不给出产物结构：环氧那篇只说环氧环容易开环，而 C20H28O5 这个分子式下既有两个环氧开环的区域异构体，也有内酯水解生成的羧酸，所以分子式能锁定反应类别，锁不住产物身份；二苯乙烯苷那篇只说蒸制会使苷含量下降，没有点名苷元，C14H12O4 在 PubChem 里只有一个异构体，这一层没有歧义，但缺少可对照的参照结构。这两行记录的不是错误产物，而是未经确认的产物。

单味药的结果取决于种子如何挑选。按默认的 marker 顺序取 12 个成分时，甘草跑出了甘草次酸，人参没有跑出 Rg3，附子的苯甲酰乌头原碱出现在另一个规则族下。纳入前体后，三个目标都在文献所述的规则族下复现。差别来自取样，不是化学：Rg1 与 Rb1 按 marker 顺序排在 12 名之外，而水解产物只有在它的前体被选作种子时才会出现。

复方里同一套化学跨药材生效。四逆汤中，附子四个二萜酯由同一个规则族水解，甘草成分提供驱动反应的酸。单煎甘草与两味合煎得到相同的产物族；产率无法比较，因为系统不建模浓度与回收率。另外三个方（桂枝汤、麻黄汤、小柴胡汤）没有带来新的规则族，验证就此停止。

这张表有两条限制。案例是按「有文献记载」挑的，不是抽样，所以这些数字说明的是「已知该产物时引擎能否到达」，不是「遇到未知产物时能否命中」。第二条是来源数。完整性要求是单向下限：有两篇以上独立文献记载的产物，必须出现在我们的输出里；只有一篇记载的产物，出现与否不作要求。本表多数行只有一篇来源，所以这条下限目前尚未被检验。

另有一组更小的对照，在首次运行之前就已写定，也没有参与规则设计：栀子苷到栀子苷元、苦杏仁苷到野樱苷、马钱苷到马钱苷元、天麻素到 4-羟基苯甲醛、士的宁到异士的宁、番泻苷 A 到番泻苷元 A。其中三个通过糖苷水解到达结构级。天麻素停在苄醇，因为规则集只氧化烯丙醇；番泻苷 A 停在单侧脱糖的中间体，因为协议只跑一轮，除非有文献点名的中间体可用；士的宁没有任何产物，因为分子内重排没有对应规则。三个失败都在通用规则层，不在炮制层，且都没有靠补一条针对性规则消除。这组案例的用途是量出这个缺口，不是逐行把它补平。

药材解析审计

解析级联测试了 75 个输入：20 个精确中文名、10 个别名、10 个炮制品、25 个取自药材表的双名学名，以及 10 个本不应被解析的字符串。

输入组	n	已解析	未解析	有歧义
精确中文名	20	20	0	1
别名	10	9	1	1
炮制品	10	3	7	0
表内拉丁双名	25	25	0	0
非药材字符串	10	1	9	1

“有歧义”表示结果不止一个，但仍计入已解析输入。10 条非药材字符串中有 1 条被解析，属于误返回。

20 个精确中文名全部成功。别名命中 9/10，只有寸冬为空。炮制品命中 3/10；其余 7 个，包括炒白术和姜半夏，都返回“库中无此条目”，没有被拆成基原。这符合炮制品闸的设定。

拉丁名路径暴露了更具体的问题。25 条表内双名都能回到自身，因为条目原本就存植物名。常用中药记录存的是药典药材名，例如甘草记录为 Radix et Rhizoma Glycyrrhizae，不是 Glycyrrhiza uralensis。用户输入 Glycyrrhiza uralensis 时，结果落到甘草节，而不是甘草根。若要稳定支持这类查询，当前字段需要拆成“药材名”和“植物学名”两列。

同一次审计里，生地黄被分配给鲜地黄和干地黄，因为表里没有生地黄本身；寸冬作为麦冬别名仍然为空。

10 个不应解析的字符串中，9 个正常返回空。唯一的例外是单字“甘”，它返回 40 个候选并触及子串上限。这个结果属于误命中，不能算解析成功。

表内双名能够匹配，并不说明常用中药的植物名查找已经可靠。Glycyrrhiza uralensis 是这项用户路径唯一的测试，而且落到了错误药用部位，因此现有版本还不能可靠处理这类查询。

审计脚本保存在 `tools/audit_herb_resolution.py`，用例清单还可以继续加。

中医药案例

以 12 个甘草成分为输入运行后，得到 573 个候选产物和 573 条出处路径。每条路径都带源成分、反应规则、轮次、方向标记和条件标记。这次运行只用于检查报告机制，不能据此讨论药效。

字段级审计区分“字段是否填写”和“字段是否有实质内容”。573 条记录中，9 个字段组全部填满，表面覆盖率为 100%；真正带条件依据的只有 7 条，占 1.2%（Wilson 95% CI 0.59% 至 2.50%）。其余 566 条写着“无 ORD 条件数据，放行”，说明条件层没有找到匹配记录，候选被保留下来，却没有条件说明。因此，字段齐全并不代表证据完整。

`tools/audit_provenance_completeness.py` 可以对任意台账重跑。方剂解析保留所有同名版本，并列出选中的来源层级和未解析词元。一次运行遇到多个版本时，输出会同时列出选中项和备选项。

公开演示与功能边界

公开演示包含 100 味常用药材，每味绑定一个拉丁物种，并含 50 个方剂和 150 条预计算记录。页面不提供任意 SMILES 入口、路线搜索、自由试剂、可购砌块或供应商链接。源数据库只读，程序只写入自己的报告和运行目录。需要受控实验时，仍可使用研究界面。

两级过滤

四君子汤的 3,210 个候选先按规则来源缩减：只保留中医药规则，去掉从 ORD 挖出的通用有机合成模板，剩下 1,114 个。随后把每个产物的 InChIKey 与 31,646 条药材成分比对，其中 6 个属于已知成分，1,108 个不属于。

6 个已知产物中，4 个来自酯水解，2 个来自糖苷水解。两轮过滤合计去掉 99.8% 的候选，需要人工查看的结构从 3,210 个降到 6 个。这个数字只表示上述结构已有文献身份。

过滤只依据两项二元检查：规则是否来自中医药规则库，以及成分是否出现在药材表中。程序不计算置信分。表外的 1,108 个产物单独标记后继续保留，它们可能是新成分，也可能是错误产物。

运行时间校准

甘草实验还测了两种上限：每味药取多少成分，以及一次处理多少底物对。

成分上限	底物数	底物对	产物数	时间
24	24	276	3,666	18.5 秒
64	64	2,016	33,579	166 秒
128	128	8,128	97,670	429 秒
342（全部）	342	58,311	359,141（上界）	33 分钟

按特异性排序时，24 个成分已经覆盖全部特征性成分。把上限提高到 128 会产生更多产物，却没有新增特征性条目。全量数据必须切片执行：分成 30 片、每片 2,000 对后，总时间 33 分钟，输出 359,141 行。去重只在片内完成，跨片重复仍在，所以这个总数是上界。

底物对预算	实际底物对	产物数	时间
500	500	9,914	50 秒
1,000	1,000	17,826	77 秒
2,000	2,000	27,076	109 秒
4,000	4,000	54,103	259 秒
8,000	8,000	120,487	573 秒

底物对增加时，产物数和耗时同步增长。这个上限只决定等待时间和覆盖范围，不是化学质量门槛。

没有产生改善的尝试

全量运行耗时约 33 分钟。我们围绕它试了四项改动，输出都没有变化。

单底物结果跨批次缓存没有作用。1,000 个底物对用了 72 秒，主要耗在 11,000 次 RDKit `RunReactants` 调用上，每次约 6.5 毫秒。单底物部分不是主要开销。

底物对索引改为按需生成，不再先构造全部 58,311 个元组，结果也没有变化。

每 200 个底物对向磁盘写一次产物。峰值内存从 1.8 GB 降下来并保持平稳，但整体比 2,000 对切片慢 60%。批次太小时，初始化成本把收益吃掉了。

四进程并行在逻辑上没问题，切片彼此独立，前四片产物数与串行一致。实际运行卡在内存：每个工作进程约占 1.7 GB 的产物对象，四个进程把 16 GB 机器耗尽，其中两个没有留下错误信息就被终止。加载全部 82,000 条模板只需要约 37 MB，显然不是模板库占内存。

想继续降内存，只能改产物对象字段，或者把出处查询推迟到写行时。这次没有改到引擎对象层。

模板路线走到哪里为止

模板只有在底物满足它的原子环境时才会开火。为了量出这个约束的代价，我们按反应中心签名给反应分组：成键与断键的条数，加上每个参与原子的元素、形式电荷、度数、芳香性、是否成环和氢数。在 60,200 条抽样 ORD 记录中，45,478 条（75.5%）能算出签名，落入 4,789 个不同的类型。样本数不

少于 100 的类型有 87 个，覆盖 28,711 条记录；不少于 10 的有 405 个；另有 5,195 条记录所在的类型只出现过三次或更少。

召回率跟着这个顺序走。每层抽 400 条，冻结配置在常见类型上为 61.3%，在样本数 10 到 99 的类型上为 31.8%，在三次或更少的类型上为 6.0%。把模板池整体打开、去掉支持度门槛并放宽两个上限后，三个数变成 63.0%、41.5% 和 8.0%。中间那层是被装载门槛压住的，不是语料里没有化学；尾部几乎没有动。

我们随后试了四种把尾部捞回来的办法，每一项都以运行前写定的判据来判。

干预	效果	代价
全量模板池，去掉支持度与上限	常见 61.3 到 63.0，中等 31.8 到 41.5，稀有 6.0 到 8.0	官方切分 top-1 由 68.2% 降到 63.1%（第一版重排序器），候选 33 到 52
生产池并入 10% 的 ORD 挖矿分片	稀有层 12.5% 到 17.5%	中位候选 35 到 491
放宽原子环境，丢掉氢数、度数与环归属	稀有层 120 条中由 26 条到 27 条	中位候选 44 到 86
借用同类另一条记录的模板	265 条中 0 条	无

有两行需要单独说明。并入更大的挖矿池确实能碰到更多稀有产物，但正确产物随之落在中位 491 条而不是 35 条的候选表里，覆盖问题就换成了排序问题。放宽原子环境只多一条命中，候选却翻倍，原因是结构性的：键级写在方括号外、芳香性写在元素符号里，这两项本来就没被放宽。真正被放宽的只有氢数、度数和环归属，而这三项正是决定哪个原子反应的字段。放宽后的模板池是以并集方式与原池一起评的，所以这个比较不可能因为构造而丢候选；若改为替换，稀有层只有 24 条。

真正的约束是表示，不是语料。一条 SMARTS 模板匹配一种字面环境，而同一种转化如果在一千种环境里出现，就需要一千条模板。扩大池子、降低支持度门槛、放宽环境，三者的缩放方式相同：候选涨得比覆盖快。这也限定了头条数字该怎样读。91.69% 的正向召回描述的是语料反复出现的反应类型；在语料里只出现过三次或更少的类型上，召回不到一成。

这些分层来自条件记录的 6.5% 抽样，且 24.5% 的抽样记录算不出签名，所以第一段的分层计数描述的是抽样语料而非全量。第二段的三个召回值各由 400 条反应得到，每条约有两个点的抽样误差。

讨论

这项工作的直接结果，是每条预测产物都能回到具体的输入记录、模板、源成分和条件标记。中医药场景尤其需要这一步。药名、炮制品、拉丁名和方剂版本经常看起来指向同一对象，实际却对应不同材料。解析路径至少能让读者看到系统最后用了哪一条。

出处链并不能替反应化学作担保。模板指向哪条 ORD 记录，只说明模板从哪里来；条件窗口只说明某类记录里出现过什么，不等于动力学、收率和选择性已经算清楚。模板库换了，或者本地数据快照更新了，结果仍可能变化。

公开版和研究版做的事情不同。公开版只展示固定目录，任意目标逆合成、自由试剂、可购砌块和供应商链接都没有入口；研究路径由环境变量恢复。这能减少误操作，但代码是可见的，控制不了愿意修改代码的人。

冻结的 USPTO-50k 实验中，选定配置比基线高。两边都有截断，选定配置的候选数和命中数也一起增加。这组数字支持配置在本文测试条件内有效，不能延伸到化学可行性、生物活性或临床疗效。

应用

Christos 可以列出必须在数味药共同加热后才会出现的结构。四君子汤示例中，过滤把 3,210 个候选压到 6 个已知成分。若两个前体分别来自不同药材，这条产物记录就为组合反应提供了线索，但最终仍要做实验。

乌头碱在第一轮水解成苯甲酰乌头原碱，再水解成乌头原碱，和附子炮制中的关键步骤一致。煎煮后出现、原药材中没有的产物，可以拿来做质量标志物筛选。上述应用只是研究起点，还不是经过验证的标志物或炮制终点。

展望

新产物怎样接上毒性或不良反应数据，目前还没有现成通道。可以预测天然产物骨架的靶点谱，也可以建立结构到 MeSH、结构到 RxNorm 的映射；系统现在两样都没有，工作量也超出反应引擎本身。

中医药规则库有 64 条规则，按文献系统整理后可以扩展到数百条。质量守恒、条件窗口和文献先验有望继续减少人工检查。最缺的仍然是实验：这里只判断软件和证据来源内能不能走到某条转化，没有回答具体实验条件下会不会发生。

局限

结果首先受模板库和候选上限约束。模板缺失会直接断掉一条可能正确的路径；上限太低时，正确产物可能排在本轮生成范围之外。程序会记录截断和底物对覆盖情况，但现有运行仍算不出未截断时的完整召回率。结果中的分层分析把这一点进一步收紧：召回数字对语料反复出现的反应类型成立，对只出现三次或更少的类型不到一成。五项文献案例中有四项的本地结构缺少立体信息，只能比较到连接层。

本研究没有做实验室验证。条件档案来自反应记录和文献，不等于收率、选择性、溶剂效应或降解实验。下游风险标注也只对已有记录的化合物有用。ADMET 缓存按 InChIKey 匹配，只覆盖一次煎煮运行产物的 2.6%；CTD 用化学名匹配，同一批新结构几乎全部落空。两个示例方剂中，ADMET 缓存给温和组合的 84 个已标注产物记录了 0 个急性毒性高分。它给含附子方剂的 169 个产物记录了 65 个高分。这个差异只覆盖已经被外部数据收录的少数结构。

中药标识符的问题还没有解决。药材名、炮制品、物种、方剂版本和来源层级都可能带来歧义。程序会报告未解析词元，不会替用户编一条看起来合理的记录。审计中，10 个炮制品有 7 个未解析，10 个别名有 1 个未解析；拉丁名字段还把植物名和药典药材名混在一起。另一方面，中医药表受库主或第三方条款约束，公开包只带固定摘录，无法单独复现中医药规模统计。

条件证据依旧稀疏。很多模板没有可用条件类别。没有标记只说明数据里没有匹配项，不能据此判定反应不会发生。中医药文献产物都在第一轮被复现，但当前每次运行仍返回 24 至 102 个候选。学习型重排序不用于这些运行：它只在专利反应上训练，没有中医药训练数据，因此默认顺序仍是发射顺序。

公开界面降低了敏感功能被随手打开的概率，不能替代法律审查、机构管理或安全评估。数据再分发仍受数据卡中的来源许可和所有权条款限制。

AI 辅助与它的失效方式

本实现的大部分、若干规则条目、审计脚本以及本文草稿，都是在引入大语言模型的条件下完成的。科学判断仍由作者承担：接受哪些转化、冻结哪些基准、哪些结论有数据支撑。

助手可以写出流畅但没有证据支撑的论断，也包括引用一篇真实存在、但说的不是这回事的论文。为此我们把每个报告中的数字都接到冻结的结果文件上，而不是接在文字叙述上，并对文献层做了机器核对。全部 25 条引用 DOI 都通过 Crossref 或 doi.org 解析，据此改正了 7 处标题错误和 3 条未注册但文章确实存在的 DOI。全部 25 条引句都与取回全文做了比对：14 条逐字一致，1 条只有标点差异，6 条只匹配到摘要，2 条无法取到全文，没有任何一条在来源中找不到。每条人工整理规则都带 DOI 或印刷版标识加引句，没有一条 SMARTS 是在这条要求之外写出来的；仅由单一二手来源支撑的规则已单独标注。

这些检查限制的是伪造引用与虚构出处，限制不了「听起来合理但化学上错误」的论断。DOI 层面的核对无法证明所引论文支持它旁边的规则，而一条错误规则可以通过全部文献学检查。代码层面的缺陷也反复出现：64 条人工整理规则里有 58 条从未加载，还原规则通过了只允许空气的条件闸，还有一处审计查询读了平面结构列，使一次立体化学比较看起来像数据缺口。这些问题都是靠运行系统发现的，不是靠阅读代码发现的。因此本文报告的数字应当被理解为「产出它的那套可执行配置的性质」，每次版本随附的闸门记录才是可以核对的对象。需要某个具体行为时，请按文中列出的命令重跑，而不是只依赖本文对它的描述。

我们试过但没有走通的生成式路线

模板只能匹配字面上的局部环境，因此我们还试了一条直接预测原子编辑的学习式路线。用 RXNMapper 为 50,000 条 USPTO 反应补了原子映射（置信度中位 0.769，29.8% 的行低于 0.5），其中 26,202 条进入训练。施加器是确定性的：给定真实编辑，它能还原 80.9% 的登记产物，说明这个表示本身可用。

瓶颈在分类器。在没有产物可参考的 150 条官方测试反应上，模型预测的单个编辑只有 3.3% 还原出登记产物。再加一级「原子存活」模型（判断哪些底物原子进入产物）后升到 6.0%；该存活模型单独看，原子级 AUC 为 0.946，60.7% 的反应原子数完全判断正确。差距来自算术：对 25 至 40 个原子逐个独立判断会连乘，单原子 0.946 对应整组约 61%，编辑环节再打一次折。

工作记录里出现过两个更漂亮的数字，它们没有通过这项检验。单编辑命中 30.9% 与并集提升 4.0 个百分点，都以产物侧的原子映射号作白名单，等于把答案的原子集合交给了求解器；去掉之后同一份代码只余 3.3%。要跨过这段差距，需要把原子集合与编辑一起联合生成，我们没有做这一步。

结论

Christos 的目标是让反应预测结果更容易核对。五条文献转化都在第一轮被复现，且都使用预期水解规则；其中三例可确认完整立体结构，乌头碱两例只能确认到连接层。四君子汤经过两级过滤，从 3,210 个候选留下 6 个已知成分。

审计还暴露了几处实现问题。64 条人工整理规则中有 58 条从未加载；还原规则通过了只允许空气的条件闸；带实质条件证据的出处条目只有 1.2%；拉丁名字段存药名而未存植物名。我们据此修改了代码，也将审计结果保留在论文中。

正向召回率 91.69%，逆向覆盖率 94.74% 和 79.81%，这些数字都只对应本文的反应引擎测试。药材输入和出处另做评价。Christos 留下的是一套可以复查的结果生成记录；预测产物能否在某个具体流程中生成，还要靠实验判断。

数据与代码可用性

代码、协议、结果表、图件源文件和可运行脚本位于 https://github.com/VegFisx/Christos，归档于 https://doi.org/10.5281/zenodo.23499423。文献验证输出包括 `reports/paper/literature_validation_20261030.json`、`reports/paper/literature_validation_20261030.csv`、`reports/paper/literature_validation_pubmed_20261030.xml` 和 `reports/paper/pubchem_literature_validation_20261030.json`。基准结果表带有 `stereo_on_full50k`、`stereo_on_unfiltered_full50k`、`legacy_on_full50k` 和 `legacy_off_full50k` 四个标记；所有正向运行都在产物规范化时保留立体化学。本文头条数字对应归档快照 `694d2de`，运行时设置 `CHEMCREACT_STEREO_CANON=1`。当前默认代码在此基础上增加了一处改动，即重写后的温度判据，召回为 92.01%（50,016 条中命中 46,020 条，Wilson 95% CI 91.77% 至 92.24%），结果表为 `stereo_on_default_20261104`。同一份代码关闭立体化学后为 82.77%。把同一次重跑应用到降档的基线配置，得到 55.53%（结果表 `baseline58_20261107`），对应冻结值 58.73%。下游标注使用 TDC ADMET Group（Huang et al., 2022）、Tox21/ToxCast 端点（Richard et al., 2016, 2021）、CTD（Davis et al., 2026）和 OnSIDES v3.1.1（Tanaka et al., 2025）。OnSIDES 用于下游评价准备，不参与本文头条结果。药典 overlay 从《中国药典》2025 年版经第三方结构化仓库 `Independent-KBs` 派生。该仓库未声明仓库级许可证，因此 overlay 仅限内部使用。上游原始数据不再分发。公开演示包是固定预计算样本，不包含生产数据库。

参考文献

下列期刊和会议引用已分别于 2026-10-19 和 2026-10-29 核对。DOI 记录通过 Crossref 解析；软件、数据集和会议条目通过各自官方项目页、EPA 页面、GitHub release 和固定提交页面核对。API 快照存于 `reports/paper/reference_verification_20261019/` 和 `reports/paper/reference_verification_20261029/`。

1. Chen, B., Li, C., Dai, H., & Song, L. (2020). Retro*: Learning retrosynthetic planning with neural guided A* search. *Proceedings of the 37th International Conference on Machine Learning*, PMLR 119, 1608–1616. https://proceedings.mlr.press/v119/chen20c.html

2. Coley, C. W., Green, W. H., & Jensen, K. F. (2019). RDChiral: An RDKit wrapper for handling stereochemistry in retrosynthetic template extraction and application. *Journal of Chemical Information and Modeling*, 59(6), 2529–2537. https://doi.org/10.1021/acs.jcim.9b00286

3. Genheden, S., & Bjerrum, E. J. (2022). PaRoutes: Towards a framework for benchmarking retrosynthesis route predictions. *Digital Discovery*, 1(4), 527–539. https://doi.org/10.1039/D2DD00015F

4. Genheden, S., Thakkar, A., Chadimová, V., Reymond, J.-L., Engkvist, O., & Bjerrum, E. J. (2020). AiZynthFinder: A fast, robust and flexible open-source software for retrosynthetic planning. *Journal of Cheminformatics*, 12, 70. https://doi.org/10.1186/s13321-020-00472-1

5. Kearnes, S. M., Maser, M. R., Wleklinski, M., Kast, A., Doyle, A. G., Dreher, S. D., Hawkins, J. M., Jensen, K. F., & Coley, C. W. (2021). The Open Reaction Database. *Journal of the American Chemical Society*, 143(45), 18820–18826. https://doi.org/10.1021/jacs.1c09820

6. Maziarz, K., Tripp, A., Liu, G., Stanley, M., Xie, S., Gaiński, P., Seidl, P., & Segler, M. (2025). Re-evaluating retrosynthesis algorithms with Syntheseus. *Faraday Discussions*, 256, 568–586. https://doi.org/10.1039/D4FD00093E

7. RDKit: Open-source cheminformatics. (2024). https://www.rdkit.org

8. Schneider, N., Stiefl, N., & Landrum, G. A. (2016). What's What: The (nearly) definitive guide to reaction role assignment. *Journal of Chemical Information and Modeling*, 56(12), 2336–2346. https://doi.org/10.1021/acs.jcim.6b00564

9. Sorokina, M., Merseburger, P., Rajan, K., Yirik, M. A., & Steinbeck, C. (2021). COCONUT online: Collection of Open Natural Products database. *Journal of Cheminformatics*, 13, 2. https://doi.org/10.1186/s13321-020-00478-9

10. Torren-Peraire, P., Hassen, A. K., Genheden, S., Verhoeven, J., Clevert, D.-A., Preuss, M., & Tetko, I. V. (2024). Models Matter: The impact of single-step retrosynthesis on synthesis planning. *Digital Discovery*, 3(3), 558–572. https://doi.org/10.1039/D3DD00252G

11. MolecularAI. SmartReact (version 2.0.1) [Computer software]. https://github.com/MolecularAI/smartreact

12. Huang, K., Fu, T., Gao, W., Zhao, Y., Roohani, Y., Leskovec, J., Coley, C. W., Xiao, C., Sun, J., & Zitnik, M. (2022). Artificial intelligence foundation for therapeutic science. *Nature Chemical Biology*, 18(10), 1033–1036. https://doi.org/10.1038/s41589-022-01131-2

13. Richard, A. M., Huang, R., Waidyanatha, S., et al. (2021). The Tox21 10K compound library: Collaborative chemistry advancing toxicology. *Chemical Research in Toxicology*, 34(2), 189–216. https://doi.org/10.1021/acs.chemrestox.0c00264

14. Richard, A. M., Judson, R. S., Houck, K. A., et al. (2016). ToxCast chemical landscape: Paving the road to 21st century toxicology. *Chemical Research in Toxicology*, 29(8), 1225–1251. https://doi.org/10.1021/acs.chemrestox.6b00135

15. Davis, A. P., Wiegers, T. C., Sciaky, D., Barkalow, F., Wyatt, B., Wiegers, J., McMorran, R., Abrar, S., & Mattingly, C. J. (2026). Comparative Toxicogenomics Database: update 2027. *Nucleic Acids Research*, gkag1041. https://doi.org/10.1093/nar/gkag1041

16. Tanaka, Y., Chen, H. Y., Belloni, P., et al. (2025). OnSIDES database: Extracting adverse drug events from drug labels using natural language processing models. *Med*, 6(7), 100642. https://doi.org/10.1016/j.medj.2025.100642

17. 国家药典委员会. (2025). 《中华人民共和国药典（2025 年版）》. 北京：中国医药科技出版社.

18. cliviali. (2026). *Independent-KBs：中国药典 2025 结构化知识库* [数据集]，提交 `63cfd6a`. https://github.com/cliviali/Independent-KBs （未声明仓库级许可证，仅限内部使用）.

19. Fan, R., Li, N., Xu, H., Xiang, J., Wang, L., & Gao, Y. (2016). The mechanism of hydrothermal hydrolysis for glycyrrhizic acid into glycyrrhetinic acid and glycyrrhetinic acid 3-O-mono-β-D-glucuronide in subcritical water. *Food Chemistry*, 190, 912–921. https://doi.org/10.1016/j.foodchem.2015.06.039

20. Fu, Y., Yin, Z.-H., & Yin, C.-Y. (2017). Biotransformation of ginsenoside Rb1 to ginsenoside Rg3 by endophytic bacterium Burkholderia sp. GE 17-7 isolated from Panax ginseng. *Journal of Applied Microbiology*, 122(6), 1579–1585. https://doi.org/10.1111/jam.13435

21. Ryu, J., Lee, H. W., Yoon, J., Seo, B., Kwon, D. E., Shin, U.-M., Choi, K.-J., & Lee, Y.-W. (2017). Effect of hydrothermal processing on ginseng extract. *Journal of Ginseng Research*, 41(4), 572–577. https://doi.org/10.1016/j.jgr.2016.12.002

22. Li, T.-F., Gong, N., & Wang, Y.-X. (2016). Ester hydrolysis differentially reduces aconitine-induced anti-hypersensitivity and acute neurotoxicity: Involvement of spinal microglial dynorphin expression and implications for Aconitum processing. *Frontiers in Pharmacology*, 7, 367. https://doi.org/10.3389/fphar.2016.00367

23. Huang, Q.-A., Zhang, Y.-M., He, Y., Lu, J., & Lin, R.-C. (2007). Studies on hydrolysis of aconitine. *Zhongguo Zhong Yao Za Zhi*, 32(20), 2143–2145. PMID: 18306748.

24. Kim, D.-S., & Lim, S.-B. (2017). Optimization of subcritical water hydrolysis of rutin into isoquercetin and quercetin. *Preventive Nutrition and Food Science*, 22(2), 131–137. https://doi.org/10.3746/pnf.2017.22.2.131

25. Yang, J., Lee, H., Sung, J., Kim, Y., Jeong, H. S., & Lee, J. (2019). Conversion of rutin to quercetin by acid treatment in relation to biological activities. *Preventive Nutrition and Food Science*, 24(3), 313–320. https://doi.org/10.3746/pnf.2019.24.3.313

26. Piao, X. M., Huo, Y., Kang, J. P., Mathiyalagan, R., Zhang, H., Yang, D. U., Kim, M., Yang, D. C., Kang, S. C., & Wang, Y. P. (2020). Diversity of ginsenoside profiles produced by various processing technologies. *Molecules*, 25(19), 4390. https://doi.org/10.3390/molecules25194390