Christos：一个具备来源感知输入解析与出处追踪的本地反应预测系统

文章类型：软件研究论文
作者：Dong Xinchang
单位：北京中医药大学中药学院，北京，中国
通讯作者：[待填写]

摘要

背景：反应模板能给出候选产物，但生成结果所依据的原始记录、触发模板和条件证据经常没有随产物一起显示。放到中医药（TCM）数据里，这个问题会放大：同一个中文药名可能指向药典条目、炮制品、地区别名或植物物种，方名也可能对应组成不同的历史版本。

方法：Christos 是一个本地运行的反应预测系统，支持正向枚举、逆合成和逐条结果追踪。程序分别处理五类输入，数据库以只读方式打开，输出中保留模板、源成分、反应轮次、条件标记和不确定性标记。我们在 USPTO-50k 上评价正向召回，以 ORD 目标评价逆向覆盖，并测试多步路线恢复及中医药输入解析和出处字段。

结果：50,016 条 USPTO-50k 反应中，选定配置取得 82.32% 的单步召回（41,173 条命中；Wilson 95% CI 81.98% 至 82.65%），基线为 55.43%。逆向搜索在 5,002 个目标、79,184 条模板的组合下取得 94.74% 的 any-hit 覆盖率；在全部 50,016 个目标和 3,065 条泄漏受控模板下为 79.81%。300 个目标中，深度不超过 2 和 3 时的路线发现率分别为 47.67% 和 72.33%。本地数据层包含 31,646 条药材成分记录、269,105 个 COCONUT 化合物、12,071 条方剂记录和 1,526 条药典方剂条目，3,228 条生产模板都关联到 ORD 反应标识。与八篇论文的回溯性核对恢复了五条选定水解产物的连接关系，五条都使用了预期水解规则；只有一个无手性中心的目标产物实现完整立体结构一致，其余四例因本地结构缺少立体信息，只能确认连接层一致。

结论：Christos 把输入记录、反应路径和候选产物放在同一条可检查的记录链上，“证据不足”也会被保留下来。基准数字反映反应引擎在指定测试设置下的表现，不能直接外推到化学可行性、生物活性或临床疗效。

关键词：反应预测；逆合成；天然产物；中医药；出处追踪；可复现性；反应模板

引言

实验数据或量化计算数据不足时，模板法常被用来先列出可能产物。RDKit 负责分子对象和基础化学操作（RDKit, 2024）；RDChiral 处理带立体化学的模板抽取和应用（Coley et al., 2019）；AiZynthFinder、Retro* 则把模板库接到搜索和排序过程上（Genheden et al., 2020; Chen et al., 2020）。USPTO-50k、PaRoutes 和 ORD 分别提供了常用测试集、路线基准和带实验背景的反应记录（Schneider et al., 2016; Genheden & Bjerrum, 2022; Kearnes et al., 2021）。

同一个模型换一套目标集或模板库，报告出来的召回率就可能不同。Maziarz et al.（2025）在统一框架中复评逆合成算法时观察到了这种差异；Torren-Peraire et al.（2024）则显示，单步模型的选择会传导向多步规划结果。读到召回率时，目标集、模板库、候选上限和过滤规则都需要一并核对。

天然产物场景还要求程序说明结果从何而来。底物来自哪条输入记录、哪个模板被调用、化合物由哪个本地来源提供、条件证据是实测记录还是一般规则，上述信息不能只靠最终产物回答。同一个界面既接收分子，也接收药材、物种和方剂；标识符层级一旦混用，就容易出现表面精确、实际错配的结果。

中医药数据里，这样的错配很常见。中文药名可能指药典条目、炮制品、地区别名或植物物种，方名也可能带着不同的历史组成。化合物既可能来自药材专库，也可能来自 COCONUT 一类物种级天然产物库（Sorokina et al., 2021）。

Christos 的实现从输入解析开始。每类输入有自己的查找路径；无法解析的词元原样返回；出现多个候选时，程序不会替用户挑一个“看起来最像”的。SQLite 只以只读方式连接。产物记录保留源成分、规则、轮次、条件标记和不确定性标记。公开演示使用固定目录，任意目标逆合成、自由试剂、可购砌块和供应商链接都不开放。

本文用公开反应基准检查引擎性能，再单独检查中医药输入解析和出处字段。两部分的评价对象不同。前者看候选能否覆盖已知产物，后者看系统有没有选对来源、并如实保留已知与未知。所有候选仍是待实验检验的化学假设。

材料与方法

系统组成

代码按职责分成六块，表 1 列出了各块的实际入口：

组件	功能	主要实现
输入解析	中药名、拉丁物种、COCONUT 物种、方剂或 SMILES	`sources/herb.py`、`sources/coconut.py`、`sources/formula.py`
反应枚举	正向模板应用与级联扩展	`core/smartreact_engine.py`、SmartReact（MolecularAI，2.0.1）
逆合成	模板反转与有界路线搜索	`tools/retro_search.py`
条件层	反应类别档案与逐模板条件窗口	`conditions/`、`data/mined_top_template_conditions*.json`
出处与报告	台账、索引、HTML 报告和来源标签	`core/query_base.py`、`tools/make_report.py`
界面	命令行与本地浏览器界面	`integration/tcmai_bridge/`

来源适配器和反应引擎没有绑死。药材、物种、方剂或用户分子进入同一套反应代码后，输入侧的出处仍会随产物保留。运行环境为 Python 3.12，使用 RDKit、rdChiral、SmartReact 和 SQLite；DuckDB 只出现在离线基准脚本中。

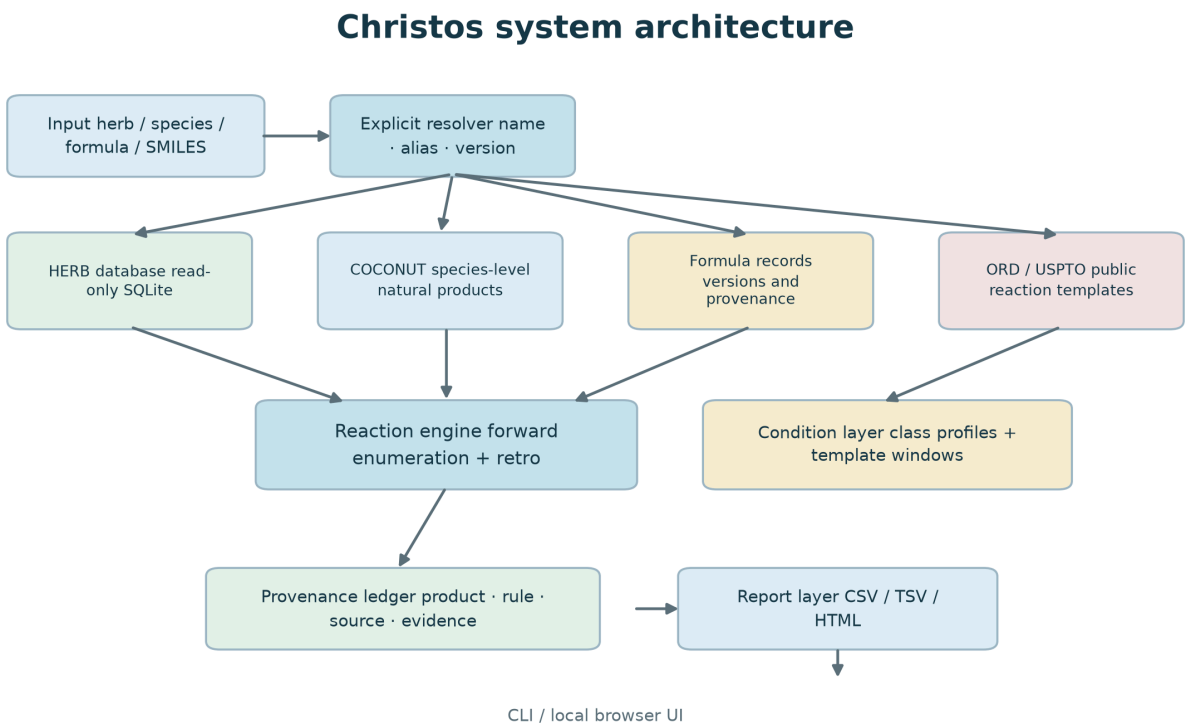


图 1. Christos 的输入与输出路径。化学模块开始运行前先解析输入；来源适配器不写入数据库；候选产物连同出处字段写入台账，再生成 CSV/TSV 和单文件 HTML。

数据源与只读策略

本地版本实际加载了以下几类资源：

资源	用途	规模	处理方式
药材数据库（`tcm.db`）	药名、成分、别名与证据	31,646 条成分记录（25,486 个不同 SMILES）	只读 SQLite
COCONUT 快照	物种级天然产物	269,105 个有效分子	只读 SQLite
方剂记录	多味方剂与版本	12,071 条	只读 JSON
药典 overlay	2025 年版方剂条目与来源 URL	1,526 条	内部使用，不再分发
USPTO-50k	泄漏受控基准	50,016 条反应	公开基准
ORD 派生模板	反应模板来源与出处	3,228 条生产模板	派生数据，署名

上游原始数据库不随本项目重新分发。ORD 派生模板按 CC BY-SA 4.0 处理；USPTO-50k 为 CC0（figshare 5104873）；COCONUT curated dataset 为 CC0，基础设施代码为 MIT；SmartReact 模板包为 Apache-2.0。本地药材和方剂资源还需库主授权，不会进入公开归档。

SQLite 连接统一加 `mode=ro`。如果 WAL 数据库因共享内存文件缺失而打不开只读连接，适配器会改用 `immutable=1` 读快照，边车文件不会新建。这个分支来自一次实际踩坑：普通 `sqlite3.connect()` 即使只打算读取，也可能顺手生成 `-wal` 和 `-shm`。

公开演示收录 100 味常用药材，每味对应一个拉丁物种，另含 50 个方剂和 150 条预计算示例。方剂控制在 4 至 6 味，并先经过安全过滤再打包。页面没有任意 SMILES 入口，也不接受路线查询。

输入解析

Christos 接收药材名、拉丁物种、COCONUT 物种、方名或一组 SMILES。药材名按以下顺序解析，直到某一层返回结果：

1. 在药材数据库中精确匹配药材名或炮制品名；
2. 炮制品闸：若药典收载的炮制品不在库中，返回“库中无此条目”，不拆回基原，也不转入别名匹配；
3. 在别名词典和药材别名列中查询，返回全部候选，不在候选之间自动选择；
4. 在人工整理的同义词表中查询，得到单一规范名；
5. 匹配中文名子串，最多返回 40 个候选，并按名称长度排序；
6. 匹配拉丁名、英文名或别名字符串；
7. 以不低于 0.85 的相似度做模糊匹配，最多返回一个候选。

拼音路径已经移除，因为查询 `gancao` 时曾匹配到秤杆草（`chenggancao`）。

解析结果里既有选中的记录，也有没有解开的词元。方剂会保留同名版本列表，再按来源层级选出一个版本。不同版本若被强行拼成一张处方，得到的组成不符合任何历史或药典条目。

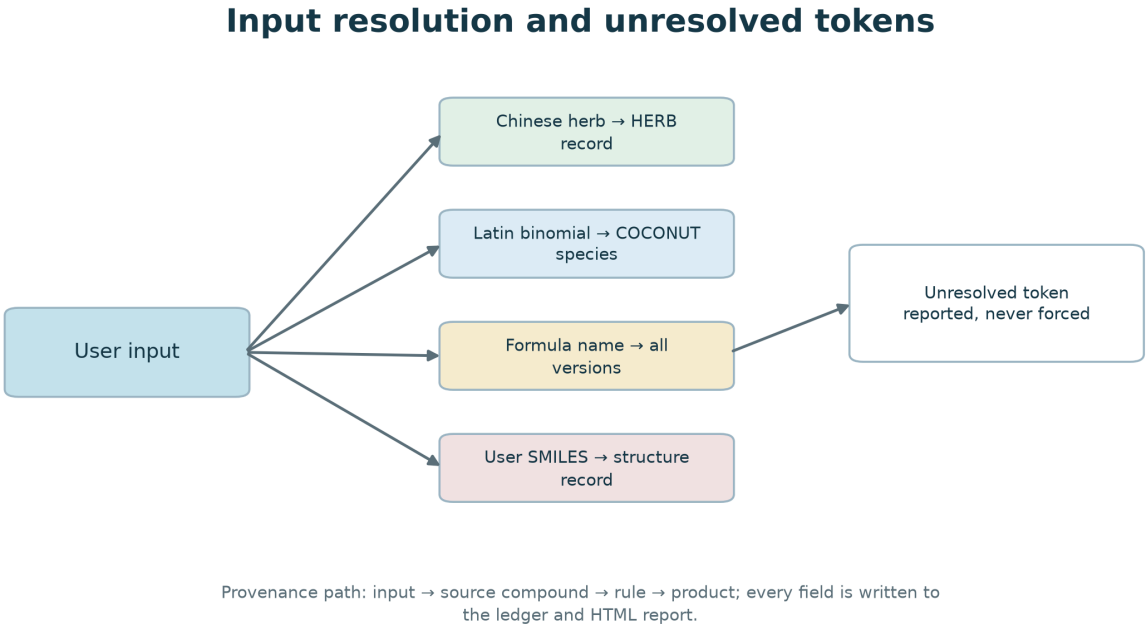


图 2. 药材名、拉丁物种、方名和 SMILES 的解析路径。未匹配词元按原样返回，不强行归入某条记录。

正向反应枚举

正向枚举对底物集合逐个应用模板。模板先按反应名称归组，再按反应物类别过滤。运行参数包括每味药的成分数、反应轮数、底物对上限，以及每个底物对保留多少候选。

选定配置采用支持度过滤的模板池，每个底物对最多保留 32 个产物，并启用底物兼容性预筛。候选上限可能在模板已经命中的情况下仍把正确产物截掉。运行记录因此会一并保存底物对覆盖率和截断状态；发生截断时，结果按不完整枚举处理。

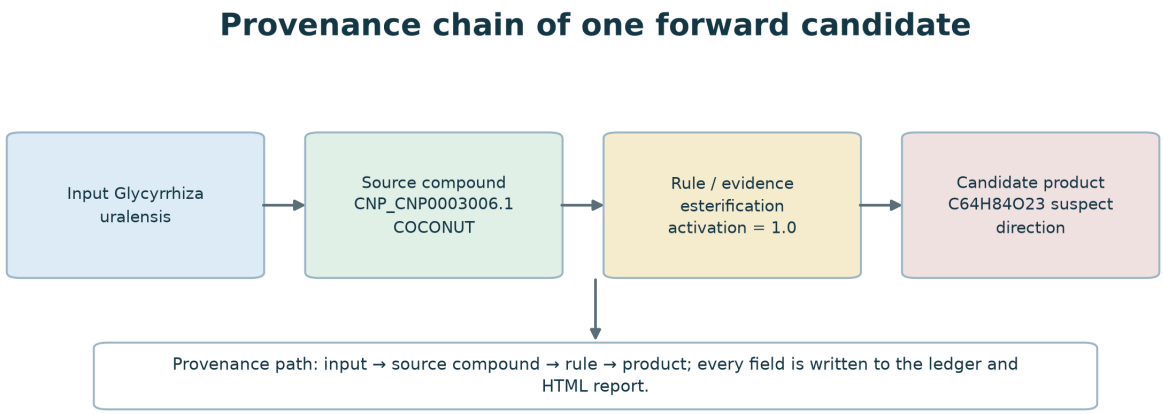


图 3. 一条正向候选及其在出处台账中保留的字段：输入物种、源成分、规则、条件证据标记和候选产物。

逆合成

逆合成使用正向模板的反向应用，从目标分子逐层找出切断、前体和整条路线的标注。前体查终止集合后标成可用或不可用。查不到只说明本地终止集合里没有它，不能据此判断现实中买不到或做不出。

公开版本不开放任意目标逆合成。研究命令需要通过单独的环境变量启用这项功能。它只改变公开界面的功能范围，并不能当作安全屏障。

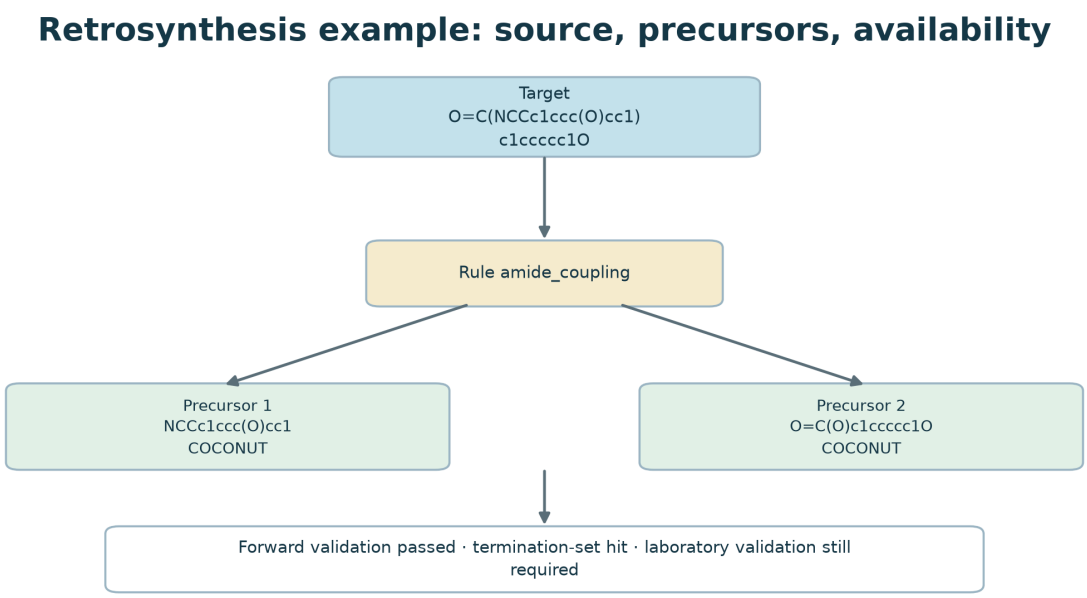


图 4. 一条单步逆合成路线，两个前体命中当前终止集合，正向验证也通过。这是标注，不是实验室操作指令。

条件证据

条件证据有两个来源：

- 命名反应类别的条件档案，包括溶剂、pH、温度、催化剂和气氛窗口；
- 从 ORD 记录中挖掘的逐模板窗口，只有模板重现了记录中的产物，才收集该记录的条件。

逐模板层从均匀抽取的 ORD 样本开始。模板必须先在记录中重现产物，之后才采用这条记录的条件。500 条受审模板里，493 条至少有一次产物匹配，491 条由此得到至少一个条件类别。条件窗口只用于标注，不计算动力学、收率或选择性。

出处与报告

台账路径逐条保存产物结构、源成分、药材或物种来源、反应规则、轮次、条件标记、方向标记和证据文字。报告生成器读取上述字段，输出单文件 HTML，并可按需绘制结构。

方向和条件标记只改变显示内容，不删候选。“无证据”表示当前记录中没有找到匹配条件，不表示反应必然不会发生。

文献一致性验证

我们在运行当前版本前固定了五个案例：甘草酸到甘草次酸、人参皂苷 Rb1 到 Rg3、乌头碱两步酯水解，以及芦丁到槲皮素。文献通过 PubMed 检索；计算所用的底物、产物和中间体均来自本地只读成分表。另从 PubChem 取得带立体化学的参考结构，用于比较连接层和立体结构标识。

每个底物单独使用煎煮条件运行一轮，开启 `strict_redox_gate=True`，每个底物对最多保留 64 个产物。产物命中要求规范化结构与文献产物一致。随后核对命中规则、规则模板中断裂的映射键、底物与产物的分子式差，以及文献中间体是否出现。对本地库中存在的中间体再单独运行一轮，检查它能否继

续生成目标产物。该流程检查计算可达性和机理一致性，不复制论文实验，也不等同于复现文献条件。

评价设计

正向预测

每条 USPTO-50k 记录只跑一轮，把记录中的反应物作为输入。目标产物只要出现在候选集合任意位置就算命中，最后不排序。评价覆盖全部 50,016 条反应，随机种子为 20261014，使用 6 个工作进程。

泄漏受控模板库先由全部 ORD 分片挖出，再做产物级去重。标准化并删除原子映射号后，产物只要与任一 USPTO-50k 测试产物相同，对应 ORD 记录就不进入模板计数；反应物是否相同不影响这一判断。两组逆向模板库也按同样规则处理。来源不同，最终规模不同：5,002 个目标的实验使用 79,184 条模板，全部 50,016 个目标的实验使用 3,065 条。

同一选定配置在过滤库和未过滤库上分别得到 82.32% 和 82.56%，相差 0.24 个百分点。就这组比较而言，模板与测试集重合只能解释很小一部分结果。

基线保留引擎默认设置，每个底物对最多 8 个产物，不加额外模板池，也不启用兼容性预筛。选定配置把上限提高到 32，再加入约 20,000 条、支持度至少为 10 的模板，并打开预筛。

基线候选中位数为 8，选定配置的第 90 百分位为 32，都已碰到各自上限。基准脚本从环境变量读取参数，结果文件只保存汇总；运行参数只能从引擎默认值和变更记录还原，原运行清单没有留下完整配置。消融显示兼容性预筛没有带来可测增益，但选定流程仍保留它。

系统本身不做候选排序。评价完整候选集合的召回率，和实际输出形式一致；Precision at k 依赖一个并不存在的排序。用户最后看到的是带出处的候选集合，第一行没有特殊地位。

逆向覆盖率

逆向命中要求至少一个切断在去除原子映射号后，得到与记录完全一致的反应物集合。5,002 个目标和 300 个目标均取自 ORD，限制为分子量不超过 500、单组分、无盐形式，从 parquet 约第 200,000 行开始抽取并去重。一组使用 5,002 个目标和 79,184 条模板；另一组使用全部 50,016 个目标和 3,065 条泄漏受控模板。目标集、模板库都变了，只能分别报告覆盖率。

多步测试使用束宽 4，每次扩展最多保留 400 个切断。搜索只要返回路线，就算“找到路线”，这条路线未必通过可用性检查。每一步都通过 `retro_search.step_usability` 才算可用路线；目标只要有一条可用路线，就算可用目标。“找到路线”比“找到可用路线”宽松。

中医药解析与出处

药材、物种、方剂和 SMILES 都从同一接口进入。每轮记录解析来源、版本、未解析词元和输出链接。演示示例由同一引擎生成，打包时固化为预计算结果，公开包中没有生产数据库。

实验配置

实验	目标集	模板库	产物级过滤	可比较对象
正向基线	50,016 条 USPTO-50k	引擎默认	是，按 USPTO-50k	正向选定配置
正向选定	50,016 条 USPTO-50k	约 20,000 条支持度过滤模板	是，按 USPTO-50k	正向基线
逆向子集	5,002 个 ORD 目标	79,184 条	是，并检查目标重合	无
逆向全量	50,016 个 USPTO-50k 目标	3,065 条	是	无
多步	300 个 ORD 目标	选定模板库	未做目标重合检查	无
条件审计	500 条模板	生产库	不适用	无
药材解析	75 个固定输入	不适用	不适用	无

正向两组共用目标集，差别只在配置，可以直接比较。逆向实验连目标集和模板库一起换了，只能并列展示。多步实验沿用选定模板库，没有再做目标级重合检查。

结果

已实现的数据规模

本地版本实际索引了 31,646 条药材成分记录、269,105 个 COCONUT 化合物、12,071 条方剂记录和 1,526 条药典方剂条目。运行时模板库有 3,228 条模板，全部能找到对应的 ORD 反应标识。公开演示另含 100 味药材和 50 个方剂。

药材表保存的是药材与成分的关联，没有先做全局去重。31,646 条记录去重后剩 25,486 个 SMILES，按记录计的重复率为 19.5%。其中 30,964 条带 InChIKey，共 29,013 个不同键。还有 682 条没有 InChIKey，所以不同键数不能拿来和不同 SMILES 数直接对照。某个成分或方剂不在统计中，只说明本次本地快照没有它。

正向预测

泄漏受控的 USPTO-50k 实验共有 50,016 条反应。基线单步召回率为 55.43%（Wilson 95% CI 54.99% 至 55.87%），每条反应平均返回 8.8 个候选，中位数 8，第 90 百分位 15；另有 1.01% 的反应一个候选也没有。选定配置的召回率为 82.32%（41,173/50,016；Wilson 95% CI 81.98% 至 82.65%），平均候选数为 21.2。六进程完成一次完整运行用了 2,820 秒。

两组配置都是候选越多、召回越高，两个数字不能拆开看。基线上限为 8，中位数已经到 8；选定配置上限为 32，第 90 百分位刚好到 32。截断是实际发生的，表中召回率只覆盖上限以内的结果。

在固定抽取的 500 条分层反应样本上进行的消融如下：

配置	召回率	平均候选数
引擎默认	41.60%	8.4
每对上限 32	64.60%	10.1
加入 20,000 条支持度过滤模板	75.80%	19.4
上限从 32 改为 64	75.80%	19.6
加入底物兼容性预筛	75.80%	19.4

把上限从 32 提到 64，召回率没有变化，平均候选数只动了 0.2。兼容性预筛在这一样本上也没有可测作用。增益主要来自更高的每个底物对上限和更大的模板池；所得数字不能证明新增模板在化学上成立。

500 条样本和全量基准的权重不同。样本给每个反应类别相同配额；全量数据里类别 1 和 2 约占 45%，而且本来召回最高。改成等权后，基线从 55.43% 降到 43.96%，选定配置从 82.32% 降到 75.22%。样本给出的两项估计是 41.60% 和 75.80%，Wilson 区间分别为 37.36% 至 45.97%、71.86% 至 79.35%，都包含对应的等权值。剩余差值仍在 n = 500 的抽样波动范围内。上表的头条结果按全量权重报告，消融表按分层样本报告。

增益来源

各反应类别的召回并不齐。默认配置在类别 1、2 上最高，在类别 4 至 7 上最低；换成选定配置后，弱类别的提升最明显。

类别	n	基线	选定配置
1	15,151	70.9%	86.9%
2	11,896	84.2%	92.6%
3	5,662	65.5%	76.0%
4	909	16.3%	52.5%
5	672	19.6%	64.7%
6	8,237	16.9%	73.2%
7	4,614	9.5%	79.2%
8	811	64.9%	81.8%
9	1,834	25.7%	68.4%
10	230	66.1%	77.0%

类别 7 提高了 69.7 个百分点，类别 6 提高 56.3，类别 5 提高 45.1。类别 2 只提高 8.4，类别 1 提高 16.0。大模板池似乎补上了弱类别的覆盖缺口，但这次比较没有检查新增模板的化学反应是否正确。

逆合成与多步规划

排除先于模板计数完成。每条 ORD 记录先查 USPTO-50k 产物集合，匹配的记录直接不进入计数。模板建好之后没有再删模板。

5,002 个逆向目标与模板挖掘来源的重合情况也查过。252 个目标（5.04%）在来源中出现过，其 any-hit 命中率为 94.84%（239/252）。其余 4,750 个目标为 94.74%（4,500/4,750）。去掉重合目标以后，覆盖率到小数点后两位都没有变化。

两组逆向实验的数值要分开看。5,002 个目标配合 79,184 条模板时，any-hit 覆盖率为 94.74%（4,739/5,002；Wilson 95% CI 94.09% 至 95.33%）。全部 50,016 个目标配合 3,065 条泄漏受控模板时，覆盖率为 79.81%。两组实验连目标集和模板库一起换了，现有结果无法分清各自贡献。

300 个多步目标没有做同样的重合检查，路线发现率也未做目标级过滤。

选定模板库下，束宽为 4 的搜索在深度不超过 2 时找到 47.67% 的路线（143/300；Wilson 95% CI 42.08% 至 53.31%），深度不超过 3 时为 72.33%（217/300；95% CI 67.01% 至 77.09%）。深度 3 以内有 207 个目标至少存在一条可用路线，占全部目标的 69.0%，占已找到路线目标的 95.4%。深度 2 以内的可用路线数没有单独保存。

每个前体都带着路线级来源和可用状态。“可用”在此仅指记录的步骤通过了本地检查，并不等于实验中可以做通。

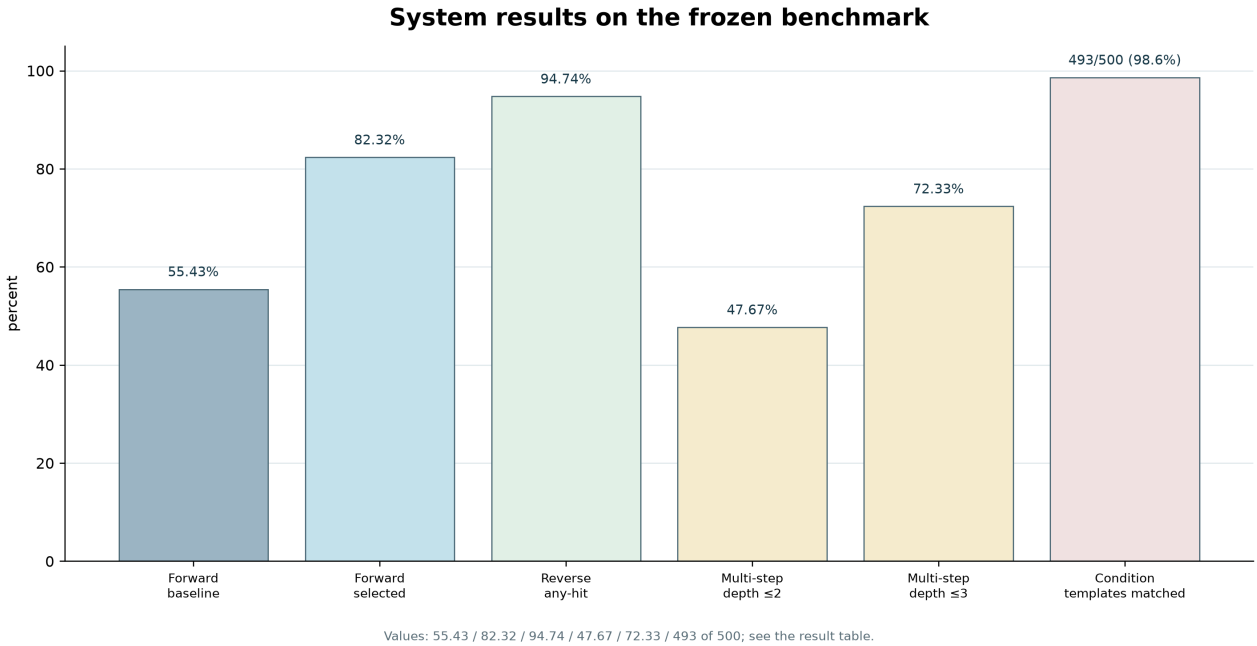


图 5. 冻结的基准测量结果。各柱使用不同任务，量纲不统一：正向单步召回（基线 55.43%，选定配置 82.32%）、逆向 any-hit 覆盖率（94.74%）、深度不超过 2 和 3 的多步路线发现率（47.67%、72.33%），以及 500 条审计模板中至少匹配一个产物的比例（493/500）。审计柱只表示产物匹配；另有 491 条模板至少有一个条件类别，但未画入图中。

条件与出处覆盖

文中出现了几个不同的计数，不能混着读。3,228 条是生产模板，也是运行时实际加载的库；约 20,000 条只属于选定基准配置，不是默认库；9,177 条是出处表引用的 ORD 反应记录；条件审计则从生产库抽了 500 条模板。

3,228 条生产模板都关联了 ORD 反应标识，出处表覆盖了全部 9,177 条被引用记录。条件审计中，493 条模板至少匹配一个产物，491 条还能给出至少一个条件类别；两条模板匹配了产物，却没有得到条件类别。审计结果是单独的数据产物，运行时模板库没有被改写。

文献一致性结果

五个目标产物都在第一轮出现，命中路径均使用预设中预期的水解规则。下表候选数来自当前版本，与较早的界面运行不同。

转化	文献	引擎规则	候选数	产物核对	路径核对
甘草酸到甘草次酸	Fan et al., 2016	`hydrolysis_glycoside_001`	63	连接层一致	水解反应族一致；文献所述单葡萄糖醛酸中间体不在本地库，逐步顺序仍未确定
人参皂苷 Rb1 到 Rg3	Fu et al., 2017; Ryu et al., 2017; Piao et al., 2020	`hydrolysis_glycoside_001`	102	连接层一致	Rd 出现，并能单独生成 Rg3；Rb1 也可直接生成 Rg3，因此引擎允许一条捷径
乌头碱到苯甲酰乌头原碱	Li et al., 2016; Huang et al., 2007	`hydrolysis_ester_001`	24	连接层一致	脱去 C2H2O 与乙酸酯水解一致；本地二维结构无法用原子映射确认 C8 位点
苯甲酰乌头原碱到乌头原碱	Li et al., 2016; Huang et al., 2007	`hydrolysis_ester_001`	27	连接层一致	脱去 C7H4O 与苯甲酸酯水解一致；本地二维结构无法用原子映射确认 C14 位点
芦丁到槲皮素	Kim & Lim, 2017; Yang et al., 2019	`hydrolysis_glycoside_001`	61	完整立体结构一致	异槲皮素出现，并能单独生成槲皮素；直接切断糖苷键也与文献反应类型一致

验证结果需要分成三层。5/5 案例在连接层命中目标产物；5/5 使用预期反应族和映射键类型；使用 PubChem 立体结构重跑时，只有 1/5 得到完整立体结构命中。另外四个本地输入缺少立体化学，因此只能算连接层一致。

逐步路径的证据也不整齐。Rb1 → Rd → Rg3 和芦丁 → 异槲皮素 → 槲皮素都能通过两次独立运行复现；乌头碱的两步可作为两个连续案例跑通。甘草酸文献同时报告单葡萄糖醛酸中间体和甘草次酸，并指出存在连续和并行水解，但该中间体不在本地库，具体先后顺序无法测试。

当前运行统一使用水、100°C、60 分钟、pH 6.5、空气。所引论文使用亚临界水、蒸制、酶转化、酸水解或长时间水解，因此这里验证的是计算可达性和反应族一致性，不能替代文献产率或条件选择性的复现。

药材解析审计

解析级联一共跑了 75 个输入，包括 20 个精确中文名、10 个别名、10 个炮制品、25 个取自药材表的双名学名，以及 10 个本不应被解析的字符串。

输入组	n	已解析	未解析	有歧义
精确中文名	20	20	0	1
别名	10	9	1	1
炮制品	10	3	7	0
表内拉丁双名	25	25	0	0
非药材字符串	10	1	9	1

“有歧义”表示结果不止一个，它仍属于已解析输入。10 条非药材字符串里有 1 条被解析，实际是误返回。

20 个精确中文名全部成功。别名命中 9/10，只有寸冬为空。炮制品命中 3/10；其余 7 个，包括炒白术和姜半夏，都返回“库中无此条目”，没有被拆成基原。这个行为符合炮制品闸的设定。

拉丁名路径的问题更具体。25 条表内双名都能回到自身，条目本来就存植物名。常用中药记录存的却是药典药材名，例如甘草记录是 Radix et Rhizoma Glycyrrhizae，不是 Glycyrrhiza uralensis。用户输入 Glycyrrhiza uralensis 时，结果落到甘草节，而不是甘草根。要让这条路可靠，当前字段必须拆成“药材名”和“植物学名”两列。

同一次审计里，生地黄被分配给鲜地黄和干地黄，因为表里没有生地黄本身；寸冬作为麦冬别名仍然为空。

10 个不应解析的字符串中，9 个正常返回空。唯一的例外是单字“甘”，它返回 40 个候选并触及子串上限。这个结果属于误命中，不能算解析成功。

表内双名成功并不等于支持常用中药的植物名查找。Glycyrrhiza uralensis 是这项用户路径唯一的测试，而且落到了错误药用部位。现有版本还不能可靠处理这类查询。

审计脚本保存在 `tools/audit_herb_resolution.py`，用例清单还可以继续加。

中医药案例

以 12 个成分为输入跑甘草，得到 573 个候选产物和 573 条出处路径。每条路径都带源成分、反应规则、轮次、方向标记和条件标记。这次运行只用来看报告机制，不能据此讨论药效。

字段级审计要回答的是“字段填了没有”和“字段里有没有内容”这两个不同问题。573 条记录里，9 个字段组都填满，表面覆盖率为 100%。但真正带条件依据的只有 7 条，占 1.2%（Wilson 95% CI 0.59% 至 2.50%）。其余 566 条写着“无 ORD 条件数据，放行”，说明条件层没有找到匹配记录，候选被保留下来，却没有条件说明。字段齐全与证据稀疏并存。

`tools/audit_provenance_completeness.py` 可以对任意台账重跑。方剂解析保留所有同名版本，并列出选中的来源层级和未解析词元；一次运行碰到多个版本时，选中项和备选项都会出现在输出中。

公开演示与功能边界

公开演示带 100 味常用药材，每味绑定一个拉丁物种，另有 50 个方剂和 150 条预计算记录。页面没有任意 SMILES 入口、路线搜索、自由试剂、可购砌块或供应商链接。源数据库只读，程序写入范围限制在自己的报告和运行目录。需要受控实验时，仍可使用研究界面。

两级过滤

四君子汤的 3,210 个候选先按规则来源缩减。只保留中医药规则，去掉从 ORD 挖出的通用有机合成模板，剩下 1,114 个。接下来把每个产物的 InChIKey 与 31,646 条药材成分比对，6 个属于已知成分，1,108 个不属于。

6 个已知产物中，4 个来自酯水解，2 个来自糖苷水解。两轮过滤合计去掉 99.8% 的候选，需要人工查看的结构从 3,210 个降到 6 个。这个数字只表示上述结构已有文献身份。

过滤条件只有两个：规则来自中医药规则库，以及成分是否出现在药材表中。程序不计算置信分。表外的 1,108 个产物单独标记后继续保留，它们可能是新成分，也可能是错误产物。

运行时间校准

甘草实验还测了两种预算：每味药取多少成分，以及一次处理多少底物对。

成分上限	底物数	底物对	产物数	时间
24	24	276	3,666	18.5 秒
64	64	2,016	33,579	166 秒
128	128	8,128	97,670	429 秒
342（全部）	342	58,311	359,141（上界）	33 分钟

按特异性排序时，24 个成分已经覆盖全部特征性成分。把上限加到 128 会产生更多产物，却没有新增特征性条目。全量数据必须切片执行；分成 30 片、每片 2,000 对后，总时间 33 分钟，输出 359,141 行。去重只在片内完成，跨片重复仍在，所以这是上界。

底物对预算	实际底物对	产物数	时间
500	500	9,914	50 秒
1,000	1,000	17,826	77 秒
2,000	2,000	27,076	109 秒
4,000	4,000	54,103	259 秒
8,000	8,000	120,487	573 秒

底物对增加时，产物和耗时一起增长。这个预算只决定等待多久、覆盖多少，不是化学质量门槛。

没有产生改善的尝试

全量运行耗时约 33 分钟。我们围绕它试了四项改动，输出都没有变化。

单底物结果跨批次缓存没有作用。1,000 个底物对用了 72 秒，主要耗在 11,000 次 RDKit `RunReactants` 调用上，每次约 6.5 毫秒。单底物部分不是主要开销。

底物对索引改为按需生成，不再先构造全部 58,311 个元组，结果也没有变化。

每 200 个底物对向磁盘写一次产物，峰值内存从 1.8 GB 降到平缓水平，但整体比 2,000 对切片慢 60%。批次太小时，初始化成本把收益吃掉了。

四进程并行在逻辑上没问题，切片彼此独立，前四片产物数与串行一致。实际运行卡在内存：每个工作进程约占 1.7 GB 的产物对象，四个进程把 16 GB 机器耗尽，其中两个没有留下错误信息就被终止。加载全部 82,000 条模板只需要约 37 MB，显然不是模板库占内存。

想继续降内存，只能改产物对象字段，或者把出处查询推迟到写行时。这次没有改到引擎对象层。

讨论

这项工作的直接结果，是每条预测产物都能回到具体的输入记录、模板、源成分和条件标记。中医药场景尤其需要这一步。药名、炮制品、拉丁名和方剂版本经常看起来指向同一对象，实际却对应不同材料。解析路径至少能让读者看到系统最后用了哪一条。

出处链并不能替反应化学作担保。模板指向哪条 ORD 记录，只说明模板从哪里来；条件窗口说明某类记录里出现过什么，也不等于动力学、收率和选择性已经算清楚。模板库换了，或者本地数据快照更新了，结果仍可能变化。

公开版和研究版做的事情不同。公开版只展示固定目录，任意目标逆合成、自由试剂、可购砌块和供应商链接都没有入口；研究路径由环境变量恢复。这能减少误操作，但代码是可见的，控制不了愿意修改代码的人。

冻结的 USPTO-50k 实验中，选定配置比基线高。两边都有截断，选定配置的候选数和命中数也一起增加。这组数字支持配置在本文测试条件内有效，不能延伸到化学可行性、生物活性或临床疗效。

应用

Christos 可以列出必须在数味药共同加热后才会出现的结构。四君子汤示例中，过滤把 3,210 个候选压到 6 个已知成分。若两个前体分别来自不同药材，这条产物记录就为组合反应提供了线索，但最终仍要做实验。

乌头碱在第一轮水解成苯甲酰乌头原碱，再水解成乌头原碱，和附子炮制中的关键步骤一致。煎煮后出现、原药材中没有的产物，可以拿来做质量标志物筛选。上述应用只是研究起点，还不是经过验证的标志物或炮制终点。

展望

新产物怎样接上毒性或不良反应数据，目前还没有现成通道。可以预测天然产物骨架的靶点谱，也可以建立结构到 MeSH、结构到 RxNorm 的映射；系统现在两样都没有，工作量也超出反应引擎本身。

中医药规则库有 64 条规则，按文献系统整理后可以扩展到数百条。质量守恒、条件窗口和文献先验有望继续减少人工检查。最缺的仍然是实验：这里只判断软件和证据来源内能不能走到某条转化，没有回答具体实验条件下会不会发生。

局限

结果首先受模板库和候选上限约束。模板缺失会直接断掉一条可能正确的路径；上限太低时，正确产物可能排在本轮生成范围之外。程序会记录截断和底物对覆盖情况，但现有运行仍算不出未截断时的完整召回率。五项文献案例中有四项的本地结构缺少立体信息，只能比较到连接层。

本研究没有做实验室验证。条件档案来自反应记录和文献，不等于收率、选择性、溶剂效应或降解实验。下游风险标注也只对已有记录的化合物有用。ADMET 缓存按 InChIKey 匹配，只覆盖一次煎煮运行产物的 2.6%；CTD 用化学名匹配，同一批新结构几乎全部落空。两个示例方剂中，ADMET 缓存给温和组合的 84 个已标注产物记录了 0 个急性毒性高分，给含附子方剂的 169 个产物记录了 65 个高分。这个差异只覆盖已经被外部数据收录的少数结构。

中药标识符的问题还没有解决。药材名、炮制品、物种、方剂版本和来源层级都可能带来歧义。程序会报告未解析词元，不会替用户编一条看起来合理的记录。审计中，10 个炮制品有 7 个未解析，10 个别名有 1 个未解析；拉丁名字段还把植物名和药典药材名混在一起。另一方面，中医药表受库主或第三方条款约束，公开包只带固定摘录，无法单独复现中医药规模统计。

条件证据依旧稀疏。很多模板没有可用条件类别。没有标记只说明数据里没有匹配项，不能据此判定反应不会发生。五条文献转化都出现在第一轮，但每次仍有 642 至 11,658 个候选要人工检查，系统不提供排序。

公开界面降低了敏感功能被随手打开的概率，不能替代法律审查、机构管理或安全评估。数据再分发仍受数据卡中的来源许可和所有权条款限制。

结论

Christos 的目标是让反应预测结果更容易核对。五条文献转化都在第一轮命中，且都使用预期水解规则；其中四条只能确认到连接层，槲皮素案例可确认完整立体结构。四君子汤经过两级过滤，从 3,210 个候选留下 6 个已知成分。

审计还暴露了几处实现问题。64 条人工整理规则中有 58 条从未加载；还原规则通过了只允许空气的条件闸；带实质条件证据的出处条目只有 1.2%；拉丁名字段存药名而未存植物名。我们据此修改了代码，也将审计结果保留在论文中。

82.32% 的正向召回率，以及 94.74% 和 79.81% 的逆向覆盖率，只对应本文的反应引擎测试。药材输入和出处另做评价。Christos 留下的是一套可以复查的结果生成记录；预测产物能否在某个具体流程中生成，还要靠实验判断。

数据与代码可用性

代码、协议、结果表、图件源文件和可运行脚本位于 https://github.com/VegFisx/Christos，归档于 https://doi.org/10.5281/zenodo.23499423。文献验证的 JSON、CSV、PubMed 快照和 PubChem 身份快照存于 `reports/paper/literature_validation_20261030.*` 与 `reports/paper/*_literature_validation_20261030.json`。下游标注使用 TDC ADMET Group（Huang et al., 2022）、Tox21/ToxCast 端点（Richard et al., 2016, 2021）、CTD（Davis et al., 2026）和 OnSIDES v3.1.1（Tanaka et al., 2025）。OnSIDES 用于下游评价准备，不参与本文头条结果。药典 overlay 从《中国药典》2025 年版经第三方结构化仓库 `Independent-KBs` 派生；该仓库未声明仓库级许可证，overlay 仅限内部使用。上游原始数据不再分发。公开演示包是固定预计算样本，不包含生产数据库。

参考文献

下列期刊和会议引用已分别于 2026-10-19 和 2026-10-29 核对。DOI 记录通过 Crossref 解析；软件、数据集和会议条目通过各自官方项目页、EPA 页面、GitHub release 和固定提交页面核对。API 快照存于 `reports/paper/reference_verification_20261019/` 和 `reports/paper/reference_verification_20261029/`。

1. Chen, B., Li, C., Dai, H., & Song, L. (2020). Retro*: Learning retrosynthetic planning with neural guided A* search. *Proceedings of the 37th International Conference on Machine Learning*, PMLR 119, 1608–1616. https://proceedings.mlr.press/v119/chen20c.html
2. Coley, C. W., Green, W. H., & Jensen, K. F. (2019). RDChiral: An RDKit wrapper for handling stereochemistry in retrosynthetic template extraction and application. *Journal of Chemical Information and Modeling*, 59(6), 2529–2537. https://doi.org/10.1021/acs.jcim.9b00286
3. Genheden, S., & Bjerrum, E. J. (2022). PaRoutes: Towards a framework for benchmarking retrosynthesis route predictions. *Digital Discovery*, 1(4), 527–539. https://doi.org/10.1039/D2DD00015F

4. Genheden, S., Thakkar, A., Chadimová, V., Reymond, J.-L., Engkvist, O., & Bjerrum, E. J. (2020). AiZynthFinder: A fast, robust and flexible open-source software for retrosynthetic planning. *Journal of Cheminformatics*, 12, 70. https://doi.org/10.1186/s13321-020-00472-1

5. Kearnes, S. M., Maser, M. R., Wleklinski, M., Kast, A., Doyle, A. G., Dreher, S. D., Hawkins, J. M., Jensen, K. F., & Coley, C. W. (2021). The Open Reaction Database. *Journal of the American Chemical Society*, 143(45), 18820–18826. https://doi.org/10.1021/jacs.1c09820

6. Maziarz, K., Tripp, A., Liu, G., Stanley, M., Xie, S., Gaiński, P., Seidl, P., & Segler, M. (2025). Re-evaluating retrosynthesis algorithms with Syntheseus. *Faraday Discussions*, 256, 568–586. https://doi.org/10.1039/D4FD00093E

7. RDKit: Open-source cheminformatics. (2024). https://www.rdkit.org

8. Schneider, N., Stiefl, N., & Landrum, G. A. (2016). What's What: The (nearly) definitive guide to reaction role assignment. *Journal of Chemical Information and Modeling*, 56(12), 2336–2346. https://doi.org/10.1021/acs.jcim.6b00564

9. Sorokina, M., Merseburger, P., Rajan, K., Yirik, M. A., & Steinbeck, C. (2021). COCONUT online: Collection of Open Natural Products database. *Journal of Cheminformatics*, 13, 2. https://doi.org/10.1186/s13321-020-00478-9

10. Torren-Peraire, P., Hassen, A. K., Genheden, S., Verhoeven, J., Clevert, D.-A., Preuss, M., & Tetko, I. V. (2024). Models Matter: The impact of single-step retrosynthesis on synthesis planning. *Digital Discovery*, 3(3), 558–572. https://doi.org/10.1039/D3DD00252G

11. MolecularAI. SmartReact (version 2.0.1) [Computer software]. https://github.com/MolecularAI/smartreact

12. Huang, K., Fu, T., Gao, W., Zhao, Y., Roohani, Y., Leskovec, J., Coley, C. W., Xiao, C., Sun, J., & Zitnik, M. (2022). Artificial intelligence foundation for therapeutic science. *Nature Chemical Biology*, 18(10), 1033–1036. https://doi.org/10.1038/s41589-022-01131-2

13. Richard, A. M., Huang, R., Waidyanatha, S., et al. (2021). The Tox21 10K compound library: Collaborative chemistry advancing toxicology. *Chemical Research in Toxicology*, 34(2), 189–216. https://doi.org/10.1021/acs.chemrestox.0c00264

14. Richard, A. M., Judson, R. S., Houck, K. A., et al. (2016). ToxCast chemical landscape: Paving the road to 21st century toxicology. *Chemical Research in Toxicology*, 29(8), 1225–1251. https://doi.org/10.1021/acs.chemrestox.6b00135

15. Davis, A. P., Wiegers, T. C., Sciaky, D., Barkalow, F., Wyatt, B., Wiegers, J., McMorran, R., Abrar, S., & Mattingly, C. J. (2026). Comparative Toxicogenomics Database: update 2027. *Nucleic Acids Research*, gkag1041. https://doi.org/10.1093/nar/gkag1041

16. Tanaka, Y., Chen, H. Y., Belloni, P., et al. (2025). OnSIDES database: Extracting adverse drug events from drug labels using natural language processing models. *Med*, 6(7), 100642. https://doi.org/10.1016/j.medj.2025.100642

17. 国家药典委员会. (2025).《中华人民共和国药典（2025 年版）》. 北京：中国医药科技出版社.

18. cliviali. (2026). *Independent-KBs：中国药典 2025 结构化知识库* [数据集]，提交 `63cfd6a`. https://github.com/cliviali/Independent-KBs （未声明仓库级许可证，仅限内部使用）.

19. Fan, R., Li, N., Xu, H., Xiang, J., Wang, L., & Gao, Y. (2016). The mechanism of hydrothermal hydrolysis for glycyrrhizic acid into glycyrrhetinic acid and glycyrrhetinic acid 3-O-mono-β-D-glucuronide in subcritical water. *Food Chemistry*, 190, 912–921. https://doi.org/10.1016/j.foodchem.2015.06.039

20. Fu, Y., Yin, Z.-H., & Yin, C.-Y. (2017). Biotransformation of ginsenoside Rb1 to ginsenoside Rg3 by endophytic bacterium Burkholderia sp. GE 17-7 isolated from Panax ginseng. *Journal of Applied Microbiology*, 122(6), 1579–1585. https://doi.org/10.1111/jam.13435

21. Ryu, J., Lee, H. W., Yoon, J., Seo, B., Kwon, D. E., Shin, U.-M., Choi, K.-J., & Lee, Y.-W. (2017). Effect of hydrothermal processing on ginseng extract. *Journal of Ginseng Research*, 41(4), 572–577. https://doi.org/10.1016/j.jgr.2016.12.002

22. Li, T.-F., Gong, N., & Wang, Y.-X. (2016). Ester hydrolysis differentially reduces aconitine-induced anti-hypersensitivity and acute neurotoxicity: Involvement of spinal microglial dynorphin expression and implications for Aconitum processing. *Frontiers in Pharmacology*, 7, 367. https://doi.org/10.3389/fphar.2016.00367

23. Huang, Q.-A., Zhang, Y.-M., He, Y., Lu, J., & Lin, R.-C. (2007). Studies on hydrolysis of aconitine. *Zhongguo Zhong Yao Za Zhi*, 32(20), 2143–2145. PMID: 18306748.

24. Kim, D.-S., & Lim, S.-B. (2017). Optimization of subcritical water hydrolysis of rutin into isoquercetin and quercetin. *Preventive Nutrition and Food Science*, 22(2), 131–137. https://doi.org/10.3746/pnf.2017.22.2.131

25. Yang, J., Lee, H., Sung, J., Kim, Y., Jeong, H. S., & Lee, J. (2019). Conversion of rutin to quercetin by acid treatment in relation to biological activities. *Preventive Nutrition and Food Science*, 24(3), 313–320. https://doi.org/10.3746/pnf.2019.24.3.313

26. Piao, X. M., Huo, Y., Kang, J. P., Mathiyalagan, R., Zhang, H., Yang, D. U., Kim, M., Yang, D. C., Kang, S. C., & Wang, Y. P. (2020). Diversity of ginsenoside profiles produced by various processing technologies. *Molecules*, 25(19), 4390. https://doi.org/10.3390/molecules25194390